

Universität Stuttgart



BOSCH

Spezialisierung einer Unfallerkennung am Zweirad mittels Smartphone auf Unabhängigkeit der Trageposition

Masterarbeit
Ausdruck: 10.01.2023

des Studiengangs Medizintechnik an der
Universität Stuttgart

Cand. M.Sc. Oays Darwish

3480821

Prüfer: Dr. Thomas Günther
Betreuer: Dipl.-Ing. Nino Häberlen
Abgabedatum: 01.03.2023



Masterarbeit

Spezialisierung einer Unfallerkennung am Zweirad mittels Smartphone auf Unabhängigkeit der Trageposition

Unternehmensbeschreibung

Bosch.IO zählt weltweit über 800 Beschäftigte aus den Bereichen Digitalisierung und IoT und arbeitet mit 30.000 Fachleuten bei ganz Bosch zusammen. Bosch baut und liefert jährlich über eine Milliarde Geräte („Dinge“) an Kunden aus den unterschiedlichsten Branchen.

Bosch.IO GmbH
Postfach 30 02 40
70442 Stuttgart
GERMANY
Besucher:
Grönerstraße 5/1
71636 Ludwigsburg
Telefon 0711 811-0
www.bosch.io

18. März 2022

Aufgabenbeschreibung

Für die breite Anwendung einer Smartphone-basierten Unfallerkennung (u.a. Beschleunigungs-, GPS-Sensor) sollen verschiedene Trage- bzw. Transportpositionen auf ihre Eignung zur Detektion von Unfällen untersucht werden.

- Analyse Unfallarten beim Motorrad aus der Unfallstatistik
- Korrelation Unfallarten zu Verletzungsschwere
- Analyse der Übertragbarkeit statistischer Daten auf bestehenden Messdatensatz
- Analyse der Merkmale verschiedener Positionen: Worin unterscheiden sich verschiedene Positionen voneinander?
- Einfluss verschiedener Messorte auf die Qualität der Erkennung von Unfallklassen
- Vergleich Messung mit Smartphone am Fahrer (z.B. Jackentasche) vs. Smartphone am Fahrzeug (z.B. Tankrucksack)
- Spezialisierung der Help Connect-Unfallerkennung zu einer robusten Multipositions-Unfallerkennung

Das Ziel ist es, eine Unfallerkennung zu entwickeln, die weitgehend unabhängig von Trage- bzw. Messpositionen an Fahrer und Zweirad funktioniert.

Kontakt

Nino Haeberlen
Bosch.IO GmbH, IOB/PAC2
Telefon +49 173 1756137
Nino.Haeberlen@bosch.io

Kurzzusammenfassung

Diese Abschlussarbeit beschäftigt sich mit der Weiterentwicklung eines Verfahrens zur smartphonebasierten Unfallerkennung am Zweirad im Taschenmodus (Pocket-Mode). Zu Beginn wird die Relevanz dieser Unfallerkennung mit aktuellen Unfallzahlen erläutert und der bisherige Unfallerkennungsalgorithmus vorgestellt. Danach wird eine Liste der Anwendungs- und potenzielle Grenzfälle anhand mehreren Videoaufnahmen von Motorradfahrten und -Unfälle vorbereitet. Im Anschluss werden einzelne kritische Szenarien wie z.B. Laufen und während einer Fahrt Anhalten näher betrachtet. Im Rahmen dieser Arbeit wird ebenfalls eine Lauferkennung mittels Matlab/Simulink implementiert. Diese wird durch eine Verarbeitung der Beschleunigungssignale aus dem Smartphone sowie die Frequenzermittlung dieses Signals mit einer FFT und danach mit einer Entscheidungsfunktion erfolgen, die die ermittelte Frequenz sowie die gemessenen Geschwindigkeit zum Entscheiden über den Laufen/Fahren-Status verwendet. Im Sinne der Lauferkennungsverifizierung und zur weiteren Betrachtung anderen Szenarien werden mehrere Versuche geplant, durchgeführt und ausgewertet. Bei der qualitativen Auswertung der Lauferkennung wird zwischen mehreren Methoden wie die Ausgabe der implementierte Aktivitätserkennung sowie die im Smartphone integrierte Aktivitätserkennung verglichen.

Abstract

This master-thesis deals with the further development of a method for smartphone-based accident detection on two-wheeler in pocket mode. The relevance of this accident detection is first explained with statistical numbers and the previous accident detection algorithm is presented. A list of use cases and potential edge cases is prepared based on several videos of motorcycle rides and accidents. Subsequently, some individual critical scenarios such as walking and stopping are analyzed in more detail. In the context of this work, a walk detection module is implemented using Matlab/Simulink. This will be done by processing the acceleration signals from the smartphone and determining the frequency of this signal with an FFT and then with a decision script that uses the determined frequency and the measured speed to decide between walking/driving status. Several tests are planned, carried out and evaluated for the purpose of verifying the walking detection and for further consideration of other scenarios. In the qualitative evaluation of the walking detection, several methods such

as the implemented activity detection and the activity detection integrated in the smartphone are compared.

Danksagung

An erster Stelle möchte ich meinen Eltern, meiner Frau und Familie danken, die mir mein Studium durch ihre Unterstützung ermöglicht haben und stets ein offenes Ohr für mich hatten. Ein besonderer Dank gilt Herrn Nino Häberlen für seine fachliche Unterstützung. Herrn Dr. Thomas Günter möchte ich dafür danken, dass er die Arbeit betreut hat. Darüber hinaus gilt mein Dank allen Personen, die beim Korrekturlesen meiner Abschlussarbeit tätig waren. Abschließend möchte ich mich bei all denjenigen bedanken, die mich während der Anfertigung dieser Arbeit unterstützt und motiviert haben.

Stuttgart, im März 2023

Oays Darwish

Inhaltsverzeichnis

Kurzzusammenfassung	v
Abstract	v
Danksagung	vii
Abbildungsverzeichnis	xi
Tabellenverzeichnis	xiii
Abkürzungsverzeichnis	xv
Symbolverzeichnis	xvii
1 Einleitung	1
2 Grundlagen	3
2.1 Unfall	3
2.1.1 Definition	3
2.1.2 Zeitliche Phasen eines Unfalls	3
2.1.3 Statistische Zahlen über Motorradunfälle	5
2.1.4 Mechanik der Motorradfahrt	9
2.2 Technische Grundlagen	11
2.2.1 Sensoren und Signale der Smartphones	11
2.2.2 Android-integrierte Aktivitätserkennung	13
2.2.3 Matlab/Simulink	14
2.3 Mathematische Grundlagen	15
2.3.1 Fast Fourier Transformation (FFT)	15
2.4 Agile Softwareentwicklung	17
2.5 Unfallerkennungsalgorithmus	17
2.5.1 Kalibrierung	18
2.5.2 Übersicht der bereits erkennbaren Unfälle	19
2.5.3 1. Feature: TipOver	19
2.5.4 2. Feature: GroundHit	22
2.5.5 3. Feature: Collision	25
3 Unfallerkennung im Pocket-Mode	27
3.1 Grund des Pocket-Modes	27

3.2	Kritische Szenarien	28
3.3	Lauferkennung	29
3.3.1	Spitzendzähler	30
3.3.2	Frequenzbasierte Lauferkennung	33
3.4	Auf- und Absteigen	44
3.5	Anhalten	44
3.6	Verifikation des Algorithmus	44
3.6.1	Versuchsplanung	44
3.6.2	Referenz-Aktivitätsdaten (Ground truth)	47
4	Ergebnisse	49
4.1	Verifizierungsversuche	49
4.2	Lauferkennung	49
4.3	Verschiedene Fahrerpositionierung	51
4.4	Anhalten	52
5	Ausblick	55
Literaturverzeichnis		xix
A	Anhang	xxiii
A.1	Matlab-Entscheidungsfunktion	xxiii
Eidesstattliche Erklärung		xxvii

Abbildungsverzeichnis

1.1	Umgang der Funktion „Help Connect“ im Fall eines Motorradunfalls	2
2.1	Einfache Darstellung des Regelkreises ‚Fahrer-Fahrzeug-Umfeld‘[H. Appel, 2002]	4
2.2	Beispiel der zeitlichen Phasen einer kritischen Fahrsituation [H. Appel, 2002]	5
2.3	Geschwindigkeitsüberschreitungen nach PKW- und Motorradfahrer an sieben Messstationen[d. Maire, 2020]	6
2.4	Unfallschwere über Geschwindigkeit aus der GAIDA-Datenbank[d. Maire, 2020]	7
2.5	Anzahl der Unfälle gegenüber Unfallgegner	7
2.6	Anzahl der Unfälle über der Art der Ursache	8
2.7	Anteil der aktiven sowie passiven Unfälle	8
2.8	Vereinfachte Darstellung der Kräfte bei stationärer Kurvenfahrt [Hädrich, 2012]	10
2.9	Verschiedene Techniken bei Kurvenfahrt mit gleicher Geschwindigkeit [Hädrich, 2012]	11
2.10	Ausgaben der Google-Aktivitätserkennung[Elbayoumy, 2018]	13
2.11	Beispiel von einer FFT (Zeitbereich und Frequenzbereich)[NTI-Audio, 2019]	16
2.12	Achsenrichtung in Sensorframe sowie in Bikeframe	19
2.13	Entscheidungsbaum des Unfallerkennungsalgorithmus anhand der drei Features sowie des Fahrzustands[Schnee u. a., 2021]	20
2.14	Erklärung der verschiedenen Features-Zustände im Entscheidungsbaum in der Abbildung 2.13[Schnee u. a., 2021]	21
2.15	Beispiel eines Fahrrads beim Umkippen mit einer ursprünglichen aufrechten Position sowie Neigung	23
2.16	Verlauf der Energie sowie des Energieschwellwerts bei einer Testfahrt ohne GroundHit	24
2.17	Verlauf der Energie sowie des Energieschwellwerts bei einer Echtfahrt mit GroundHit	24
2.18	Verlauf der Energie sowie des Energieschwellwerts bei einer echten Fahrt ohne Kollision	25
2.19	Verlauf der Energie sowie des Energieschwellwerts bei einer echten Fahrt mit einer Kollision	26
3.1	Ergebnisse der Umfrage vom Spiegelinstitute über das Taschenmodus	28

3.2	Die Use- und Edgecases mit der erwarteten Reaktion des Algorithmus	29
3.3	Beispiel eines Beschleunigungssignal beim Laufen	30
3.4	Testmodel der Lauferkennung - Spitzenzähler	31
3.5	Darstellung des im Testmodel der Lauferkennung generierten Sinussignal sowie jede Überschneidung der x-Achse	31
3.6	Skizze eines einfachen ideales Signal sowie eines komplexeres Signal . .	32
3.7	Testbeispiel - Frequenzbasierte Lauferkennung - Sinussignal	34
3.8	Testbeispiel - frequenzbasierte Lauferkennung - Ausgabe des Spektrum- Analyzers im Fall eines komplexen Signals	34
3.9	Testbeispiel - Frequenzbasierte Lauferkennung - FFT	36
3.10	verschiedene Einzelsignale ($f = 23,8; f = 47,8; f = 1,1$) mit deren Summe f_g	37
3.11	Das Ergebnis der FFT - Spiegelung entfernt und Beträge	38
3.12	Ablaufschema des Testmodels der Frequenzbasierten Lauferkennung . .	39
3.13	Das vollständige Echtmodel der Frequenzermittlung im Rahmen der Lauferkennung	40
3.14	Ein- und Ausgänge des Entscheidungsskripts	41
3.15	Entscheidungsbaum der Aktivitätserkennung	41
3.16	Abgeschnittene Teile eines Beispieldesignals	43
3.17	Winkeländerung im Signal zwischen vertikaler sowie horizontaler Smartphone- Positionierung	45
3.18	Die Zusammenfassung der getesteten Szenarien	46
3.19	Beispiel der exportierten Tabelle mit der neuen Spalte	48
3.20	Die definierte Labels von Groundtruth	48
4.1	Ergebnis des Lauferkennungsmodells	50
4.2	Beschreibung der Klassen in der Grafik Abbildung 4.1	50
4.3	Zeitlicher Verlauf der Geschwindigkeit, Ground Truth der Fahrerakti- vität und -Position sowie der Winkeländerung	52
4.4	Winkeländerung des Smartphones durch das Anhalten	53
4.5	Beinpositionen während einer Fahrt und beim Anhalten	53

Tabellenverzeichnis

3.1 Ausgangsmöglichkeiten der Entscheidungsfunktion	40
---	----

Abkürzungsverzeichnis

API	Application Programming Interface
Anova	Analysis of Variance
VSS	Verkehrssicherheitsscreening
GIDAS	German In-Depth Accident Study
MEMS	Mikro Elektronisch Mechanischen Systeme
FP	Frontalpanel (LabVIEW)
BD	Blockdiagramm (LabVIEW)
FFT	Fast-Fourier-Transformation
DFT	Diskrete-Fourier-Transformation
SF	Sensor Frame
BF	Bike Frame
NHTSA	National Highway Traffic Safety Administration
DOF	Degrees of Freedom
SPF	Schwerpunkt des Fahrers
SPM	Schwerpunkt der Maschine
API	Application Programming Interface
VI	Virtuelle Instrumente
DSP	Digitaler Signalprozessor
FFT	Fast Fourier Transformation
GPS	Global Positioning System

Symbolverzeichnis

f_s	Abtastfrequenz
B_l	Blocklänge
f_n	Bandbreite
D	Messdauer
d_f	Frequenzauflösung
λ	Neigungswinkel
F_q	Zentrifugalkraft
F_G	Gewichtskraft

1 Einleitung

Jedes Jahr wird weltweit das Leben von etwa 1,3 Millionen Menschen durch einen Verkehrsunfall beendet. Zwischen 20 Millionen und 50 Millionen weitere Menschen erleiden Verletzungen, wobei viele infolge ihrer Verletzung eine Behinderung erleben müssen. Verkehrsunfälle verursachen erhebliche wirtschaftliche Verluste für Einzelpersonen, ihre Familien und Nationen insgesamt. Diese Verluste ergeben sich aus den Behandlungskosten sowie aus Produktivitätsverlusten für diejenigen, die durch ihre Verletzungen getötet oder behindert wurden, und für Familienmitglieder, die sich von der Arbeit oder Schule freinehmen müssen, um sich um die Verletzten zu kümmern. Straßenverkehrsunfälle kosten die meisten Länder 3% ihres Bruttoinlandsprodukts. Verletzungen im Straßenverkehr sind die häufigste Todesursache für Kinder und junge Erwachsene im Alter von 5 bis 29 Jahren.[WHO, 2022]

Motorradfahren findet in Deutschland immer mehr Zuwachs. Rund 3,8 Millionen zweirädrige Kraftfahrzeuge waren am 1. Januar 2012 in Deutschland zugelassen. Dies entspricht 7,26% aller zugelassener Kraftfahrzeuge in Deutschland [Hädrich, 2012].

Motorradfahrer stellen im Straßenverkehr eine besonders gefährdete Gruppe an Verkehrsteilnehmern dar. Die National Highway Traffic Safety Administration (NHTSA) schätzt, dass Motorradfahrer im Jahr 2018 etwa 27-mal häufiger bei Verkehrsunfällen in den USA ums Leben kamen als Insassen von PKWs[Venkatraman u. a., 2021].

Verzögerungen bei der Erkennung und Behandlung der an einem Verkehrsunfall beteiligten Personen erhöhen die Schwere der Verletzungen. Die Versorgung von Verletzungen nach einem Unfall ist äußerst zeitkritisch und Verzögerungen von Minuten können über Leben und Tod entscheiden. Die Verbesserung der Versorgung nach einem Unfall erfordert die Sicherstellung des Zugangs zu rechtzeitiger präklinischer Versorgung und die Verbesserung der Qualität sowohl der präklinischen als auch der stationären Versorgung.[WHO, 2022]

Da die Reaktionszeit der Rettung eine besonders große Rolle dabei spielt, Leben zu retten, ist eine automatische Unfallerkennung von großen Bedeutung.

Bosch hat ein neues Notrufsystem namens „Help Connect“ auf den Markt gebracht, das automatisch Hilfe rufen kann, wenn es Unfälle auf Motorrädern erkennt. Der Dienst nutzt einen Unfallerkennungsalgorithmus, um festzustellen, ob ein Motorrad wirklich in einen Unfall verwickelt oder nur umgestürzt ist. Wenn „Help Connect“ entscheidet, dass ein Motorrad in einem Unfall war, übermittelt es Informationen über die Unfallstelle und den Fahrer wie z.B. der aktuelle Standort, der Schweregrad des Aufpralls und die optional hinterlegte Gesundheitsdaten an das Bosch Service Center. Im Call-Center versuchen speziell geschulte Agenten, den Fahrer zu erreichen. Wenn der zu erreichten Fahrer nicht reagiert und die Sensoren einen schweren Unfall erkannt haben, wenden sie sich mit allen Informationen an die lokale Rettungsdienste, damit sie

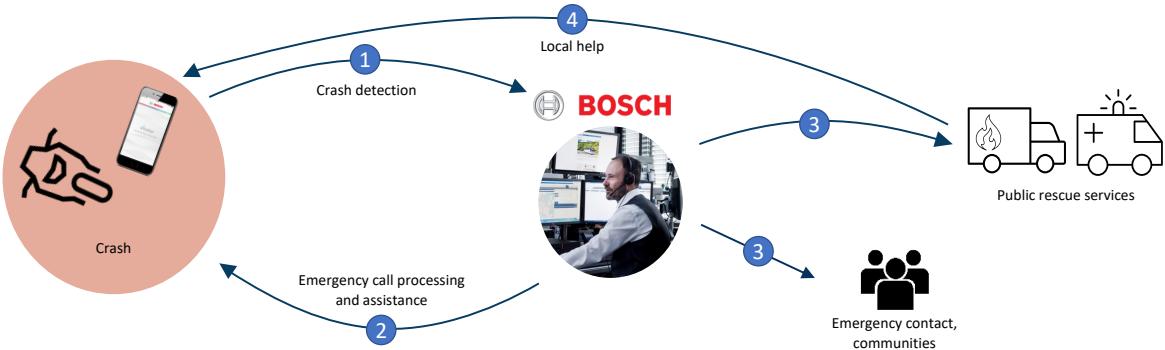


Abbildung 1.1: *Umgang der Funktion „Help Connect“ im Fall eines Motorradunfalls*

der Person so schnell wie möglich helfen können.[Gibbons, 2021][Moon, 2020][Bosch, 2021]

Die Abbildung 1.1 fasst die Ablaufschritte im Fall einer Unfallerkennung zusammen. Nachdem ein Motorradunfall durch das Smartphone erkannt wird, wird eine Benachrichtigung an Bosch Call-Center mit der Unfallschwere weitergeleitet. Der Agent versucht den Fahrer telefonisch zu erreichen, der den Unfall bestätigt oder absagt. Wenn die Person Hilfe benötigt, gibt der Agent die notwendige Informationen an die lokale Rettungsdienste weiter.

Diese Arbeit beschäftigt sich mit der Weiterentwicklung des Unfallerkennungsalgorithmus, damit dieser auch im Taschenmodus verwendbar und funktionsfähig bleibt. Darunter fällt die Ermittlung der potenziellen Verhaltensunterschiede des Algorithmus zwischen dem originalen Modus (Am Lenker) und dem Taschenmodus. Anpassungs-ideen werden vorgeschlagen und bei bestimmten Szenarien entwickelt und verifiziert.

2 Grundlagen

In diesem Kapitel wird die Relevanz der vorliegenden Arbeit erörtert und die wichtige Begriffe wie „Unfall“ näher erklärt.

2.1 Unfall

In diesem Unterkapitel wird ein Unfall definiert, die Ablaufphasen eines Unfalls erläutert sowie eine Unfallstatistik präsentiert.

2.1.1 Definition

Straßenverkehrsunfälle können in der Regel nur unter Berücksichtigung des geschlossenen Regelkreises „Fahrer-Fahrzeug-Umfeld“ erklärt, analysiert und bewertet werden. Denn die Ursachen und Folgen von Unfällen lassen sich fast nie allein auf eine Komponente des Regelkreises zurückführen, sondern sind das Ergebnis des Zusammenspiels dreier Komponenten. Unfälle werden daher fast immer durch eine Kombination von Ursachen (z.B. Blendung entgegenkommender Fahrzeuge und Fußgänger in dunkler Kleidung) und deren Auswirkung auf das Zusammenspiel mehrerer Situationen (z.B. Tragen von Schutzhelmen, Auslösen von Sicherheitsairbags, Aufpralleinwirkung) verursacht. [H. Appel, 2002]

Die Abbildung 2.1 zeigt einen vereinfachten Regelkreis des Verhaltens zwischen den drei Komponenten „Fahrer-Fahrzeug-Umfeld“. In dem Modell wurde die Ablenkung als ein Störgrößenbeispiel an den Fahrer und die nasse Straße als eine Störgröße ans Fahrzeug modelliert. Dieses Modell macht es leichter den Ablauf eines Unfalls zu verstehen und anschließend weitere Unfälle zu vermeiden. Durch eine Störung des Fahrers beziehungsweise des Fahrzeugs ändert sich der Ablauf einer Fahrt (oder eines Unfalls), da Störungen die Reaktionszeit sowie Reaktionsart der Fahrer stark beeinflussen. Diese sind im Fall eines Unfalls von großer Bedeutung.

2.1.2 Zeitliche Phasen eines Unfalls

Nach dem zeitlichen Unfallverlauf werden folgende Unfallphasen unterschieden:

- Pre-Crash-Phase (Einlaufphase): Die Einlaufphase beschreibt den Zeitraum vom Erkennen der kritischen Situation bis zum ersten Kontakt mit dem Hindernis beziehungsweise Unfallgegner.

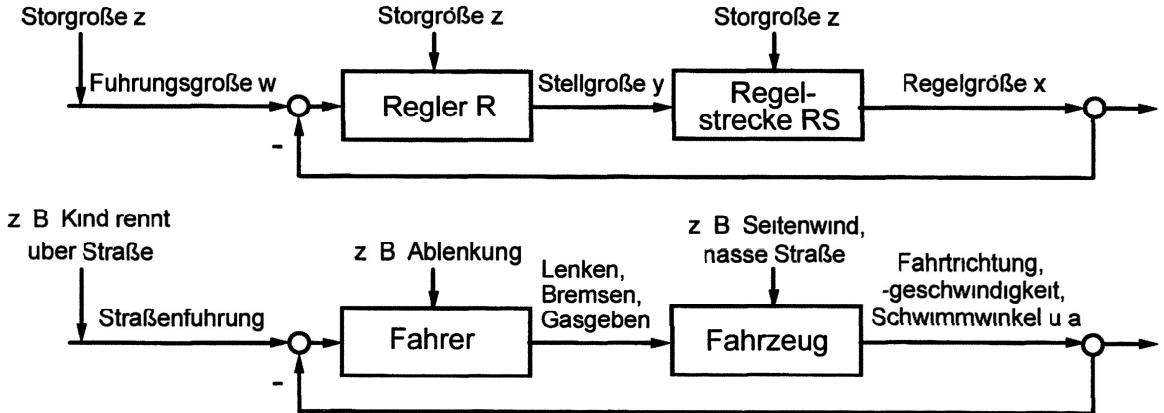


Abbildung 2.1: Einfache Darstellung des Regelkreises „Fahrer-Fahrzeug-Umfeld“ [H. Appel, 2002]

- Crash (Kollisionsphase): Der Zeitraum vom ersten Kontakt zwischen den Unfallbeteiligten bis zur Lösung. Bei Mehrfachkollisionen werden mehrere Kollisionsphasen auftreten.
- Post-Crash-Phase (Folgephase): Die Folgephase ist der Zeitraum vom Lösen der Unfallbeteiligten bis zu ihrem Stillstand. Bei Mehrfachkollision treten auch mehrere Post-Crash-Phasen auf.

Die Einlaufphase (Pre-Crash-Phase) ist maßgeblich vom Fahrer, der Straßenumgebung und der aktiven Sicherheit vom Fahrzeug abhängig (z.B. Bremsverhalten, Fahrzeugbeladung, gefährliche Kreuzungen, ...usw.).

Die Folgen der Kollisionsphase werden für die betroffenen Verkehrsteilnehmer maßgeblich durch die Maßnahmen der passiven Sicherheit (z.B. Lederkleidung beim Motorradfahrer) beeinflusst. Der Ablauf der Folgephase hängt stark von den verschiedensten Parametern beim Fahrzeug, beim Insassen und bei der Umgebung (z.B. Straßennässe) ab. [H. Appel, 2002]

Beispiel der Ablaufphasen einer Fahrsituation

Die Abbildung 2.2 zeigt ein vereinfachtes Szenario einer kritischen Situation am Beispiel einer Kurve. Diese kritische Situation kann, muss aber nicht zwangsläufig zu einer Kollision führen. Zu einem bestimmten Zeitpunkt erkennt der Fahrer eine kritische Situation. Es ist zuerst unklar, ob es zu einem Unfall kommt. Nach dem Erkennen dieser Situation obliegt dem Fahrer die Entscheidung, welche Maßnahmen zu greifen sind, um eine Unfallsituation zu vermeiden. Dabei wird der Fahrer auf bereits zurückliegende Erfahrungen zugreifen und eine zur Vermeidung dieser kritischen Situation geeignete Maßnahme ergreifen. Das Fahrzeug reagiert auf die Fahreraktionen, was zu „Fahrer-Fahrzeug-Interaktion“ führt, die zu Unfällen führen kann. [H. Appel, 2002]

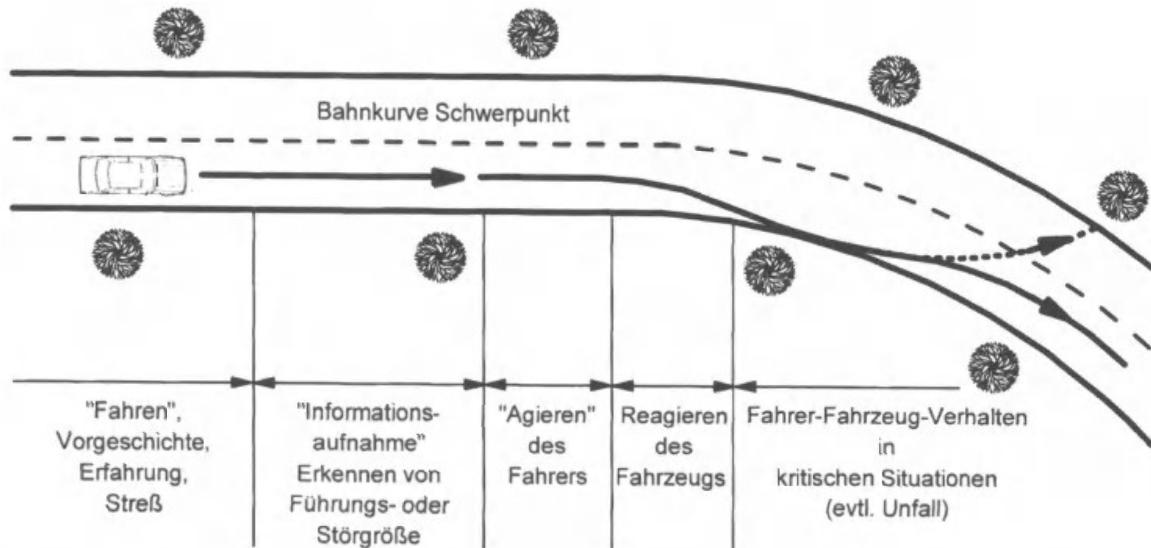


Abbildung 2.2: Beispiel der zeitlichen Phasen einer kritischen Fahrsituation [H. Appel, 2002]

2.1.3 Statistische Zahlen über Motorradunfälle

Das baden-württembergische Verkehrsministerium stellt ein Portal zur Verfügung, über das einzelne Verkehrsmessstellen abgefragt werden können. Das Verkehrsverhalten wurde an mehreren ausgewählten Stationen betrachtet. Die Messstationen wurden nach zwei Kriterien ausgewählt. Einerseits müssen Unfallschwerpunkte in unmittelbarer Nähe zu Messstationen sein, um zuverlässige Aussagen über Verkehr und Störstellen zu treffen. Andererseits muss darauf geachtet werden, dass es keine Abzweigungen zwischen der Messstation und dem Unfallschwerpunkt gibt, da sonst das richtige Verkehrsaufkommen nicht erfasst werden kann.

Die Abbildung 2.3 stellt dar, wie oft die Geschwindigkeit von Motorradfahrer sowie von PKW-Fahrer an verschiedenen Stationen überschritten wurde. Aus der Grafik ist deutlich zu erkennen, dass an sechs der sieben ausgewählten Stationen das Geschwindigkeitslimit regelmäßig überschritten wird. Die Motorradfahrer missachten die Geschwindigkeitsbegrenzung häufiger als die PKW-Fahrer. [d. Maire, 2020]

Die Daten aus German In-Depth Accident Study (GIDAS) verfügen über die Ausgangsgeschwindigkeit des Motorradfahrers, was die Ermittlung des Einflusses dieser Geschwindigkeit auf die Unfallfolgen ermöglicht. In der Abbildung 2.4 sind die Unfallschwere nach Motorradgeschwindigkeit als Histogramm dargestellt. Die Unfälle werden dabei nach Unfallschwere (leicht verletzt, schwer verletzt, tödlich verwundet) unterteilt. Die gestrichelten Linien repräsentieren die Mittelwerte der Histogramme. Die Grafik zeigt, dass die Verletzungsschwere stark von der Geschwindigkeit abhängig ist. Bei einer 0 km/h gibt es keine tödlichen Unfälle, wobei die Unfälle bei einer Geschwindigkeit von 100 km/h fast immer mit einer schweren Verletzung oder tödlichen Verkehrsteilnehmer enden. Die hohe Geschwindigkeit kommt immer mit hohen Kräften zusammen, welche bei einem Unfall dem Fahrer bewirken. Im Fall eines Motorrad-

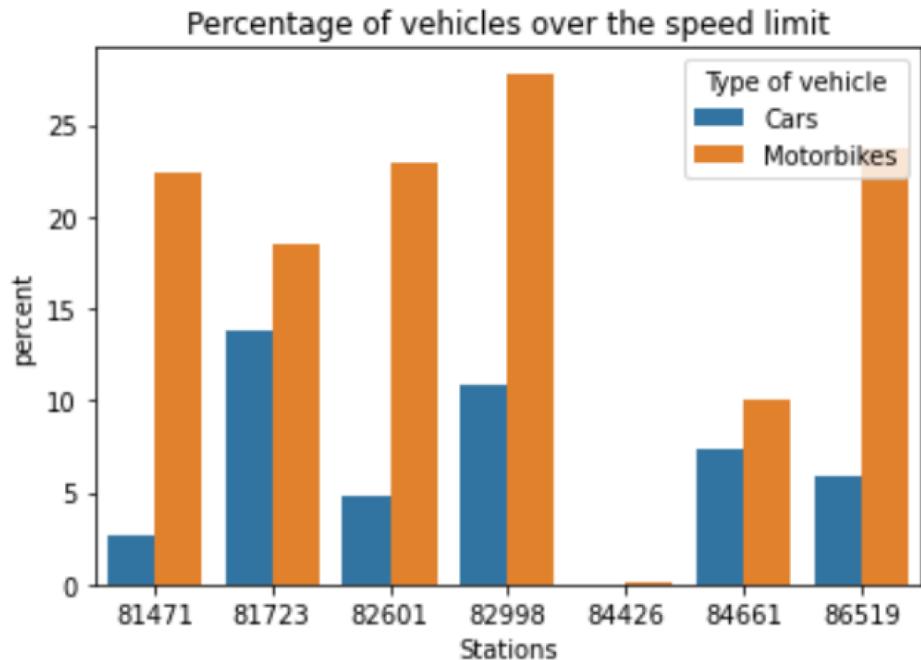


Abbildung 2.3: Geschwindigkeitsüberschreitungen nach PKW- und Motorradfahrer an sieben Messstationen [d. Maire, 2020]

fahrers ist das besonders wichtig zu betrachten, da diese Kräfte dem Fahrer direkt übertragen werden. [d. Maire, 2020]

Interne Statistik aus mehreren Videoaufnahmen

Im Sinne der Verifizierung des angepassten Unfallerkennungsalgorithmus muss erstmals bekanntgegeben werden, welche Unfälle beziehungsweise Unfallarten am häufigsten vorkommen, damit diese tief betrachtet werden. Dazu wurden mehrere Videos von Motorradunfälle auf dem Plattform „Youtube“ stichpunktartig angeschaut und die vorgestellten Unfälle statistisch analysiert. Es wurden insgesamt 32 Unfallsituationen ausgewertet. In der Auswertung wurden die Unfallgegner und der Ablauf des Unfalls betrachtet. [MostrandomComps, 2019] [Moto-Passion, 2018b] [Moto-Passion, 2018c] [Moto-Passion, 2018a] [Moto-Passion, 2018d] In der Abbildung 2.5 stellt die Grafik die Anzahl der Motorradunfälle gegenüber der Unfallgegner dar. Es wurde hier zwischen alleiniger Unfall, Unfall mit einem Gegner (Auto, Motorrad) oder Unfall wegen eines Gegenstands aufgrund der Verhaltensunterschied während eines Unfalls unterschieden. Von insgesamt 36 Unfälle waren die alleinige Unfälle am meisten gefolgt von den Unfällen mit einem Auto. Die Unfälle mit einem anderen Motorrad oder wegen eines Hindernis sind am wenigsten. Unter alleinige Unfälle werden die zwei Szenarien (An einer Kurve rutschen und Kontrolle verlieren) am meisten aufgetreten, was sehr gut in der Abbildung 2.6 sichtbar ist. Das Szenario, in dem das Motorrad an ein Auto von hinten anstoßt, hatte die dritte Stelle besetzt. Die Hauptgründe der Unfällen mit einem Gegner waren vor Allem die hohe Geschwindigkeit und das schlechte Wet-

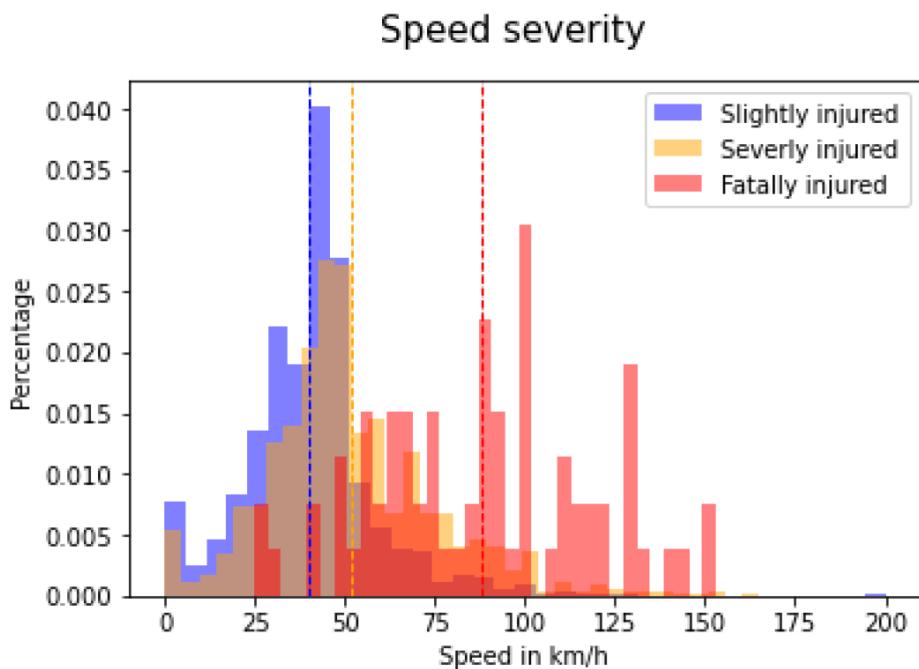


Abbildung 2.4: *Unfallschwere über Geschwindigkeit aus der GAIDA-Datenbank[d. Maire, 2020]*

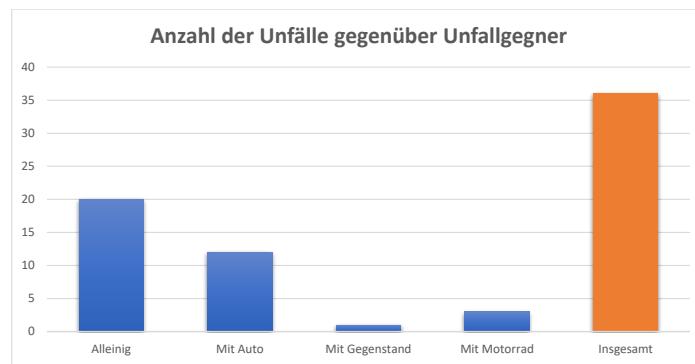


Abbildung 2.5: *Anzahl der Unfälle gegenüber Unfallgegner*

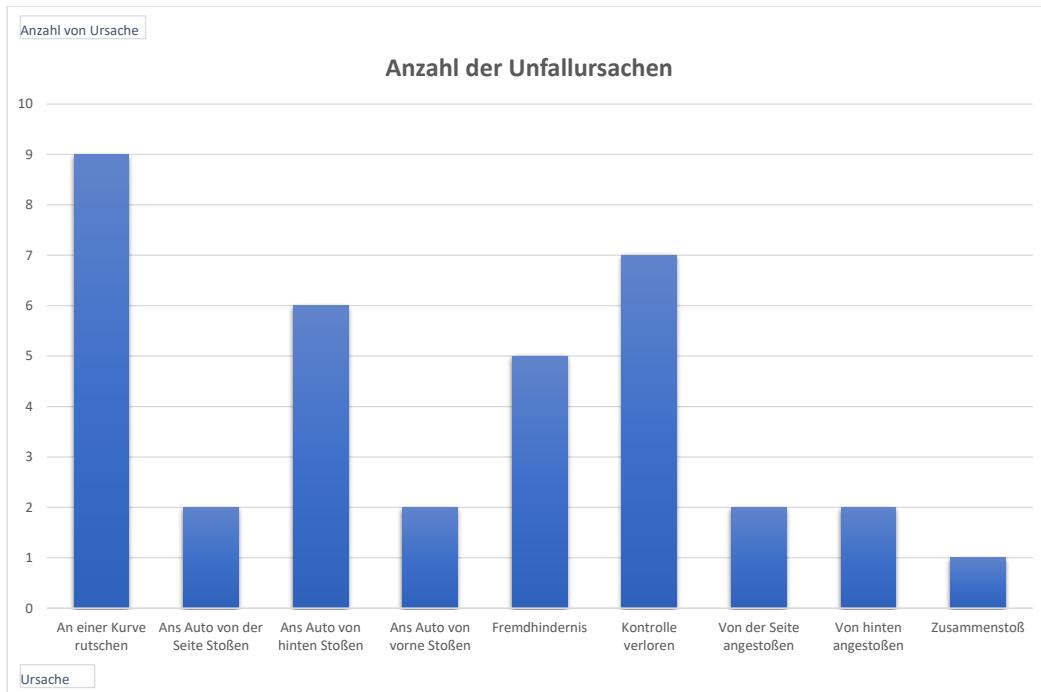


Abbildung 2.6: Anzahl der Unfälle über der Art der Ursache

ter (z.B. Nässe, Schnee), was zu Schwierigkeiten geführt hat, die kritische Situation rechtszeitig zu erkennen und das Motorrad gut zu kontrollieren.

Die Abbildung 2.7 zeigt den Anteil der aktiven sowie passiven Unfälle. Wenn das Motorrad angestoßen wird, wird von einem passiven Unfall gesprochen, da der Motorradfahrer keinen Einfluss darauf hat. Im Vergleich dazu könnte er bei einem aktiven Unfall das Ergebnis beeinflussen, in dem er langsamer fährt oder mehr Abstand mit den anderen Verkehrsteilnehmer hält.

Bilder aus den YT-Videos hinzufügen als Beispiele der Unfälle (vor Allem Alleiniger Unfall)

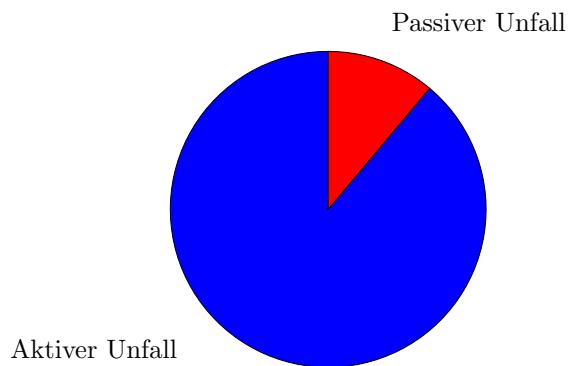


Abbildung 2.7: Anteil der aktiven sowie passiven Unfälle

2.1.4 Mechanik der Motorradfahrt

Aus kinematischer Sicht besteht jedes mechanische System aus einer Anzahl starrer Körper, die durch eine Anzahl Gelenke miteinander verbunden sind. Jeder Körper hat sechs Freiheitsgrade (DOF), da seine Position und Orientierung im Raum vollständig durch sechs Parameter definiert sind, wie z.B. die drei Koordinaten eines Punktes (x, y, z) und drei Winkel (yaw, roll, pitch). In der Praxis hat der Fahrer beim Fahren seine Hände am Lenker. Dies kann die Stabilität des Zweirads aufgrund der Schleife verändern, die zwischen dem Körper des Fahrers, dem hinteren Rahmen (wo der Fahrer sitzt) und dem vorderen Rahmen (wo sich die Hände des Fahrers befinden) entsteht.[Cossalter u. a., 2014]

Das Fahrerverhältnis während der Fahrt hat einen starken Einfluss auf die Mechanik des Motorrads. Demnächst wird die Kurvenfahrt näher betrachtet.

Kurvenfahrt

Der Fahrer bestrebt während der Fahrt immer das Gleichgewicht zu halten, damit er und das Motorrad nicht umkippt. Befährt ein Motorradfahrer eine Kurve, tritt im Vergleich zu einer Geradeausfahrt eine Instabilität im Gleichgewicht auf und versucht der Fahrer die Maschine wieder zum Gleichgewicht zu bringen. Während der gesamten Kurvenfahrt kann der Fahrer den Verlauf der Fahrlinie sowohl durch positives oder negatives Beschleunigen als auch durch die Veränderung des Lenkwinkels beeinflussen. [Hädrich, 2012]

Wirkende Kräfte am Fahrzeugschwerpunkt

Beim Einleiten einer Kurvenfahrt mit konstantem Bahnradius wirkt eine konstante Querbeschleunigung (a_q) auf die Einheit „Fahrer-Maschine“. Diese Querbeschleunigung bewirkt eine Seitenkraft im Gesamtschwerpunkt der Einheit „Fahrer-Maschine“. Die Abbildung 2.8 zeigt die wirkenden Kräfte und die daraus resultierenden Momente während der stationären Kurvenfahrt an einem vereinfachten Modell. Die Gewichtskraft

$$F_G = m_g \cdot g$$

sowie die Fliehkraft beziehungsweise Zentrifugalkraft

$$F_a = m_g \cdot a_q$$

sind in der Abbildung ersichtlich. Die Fliehkraft versucht das Motorrad nach Außen zum Kippen zu bringen, deswegen wird das Fahrzeug die Kurve unter Schräglage durchzufahren. Dadurch verschiebt sich der Schwerpunkt der Einheit zur Kurvenseite und wird ein Moment der Gewichtskraft um den Reifenaufstandspunkt resultiert, welches dem Moment der Fliehkraft entgegen wirkt und wieder ein Gleichgewicht sichert. Der Schrägwinkel (λ) der Einheit lässt sich wie folgt berechnet:

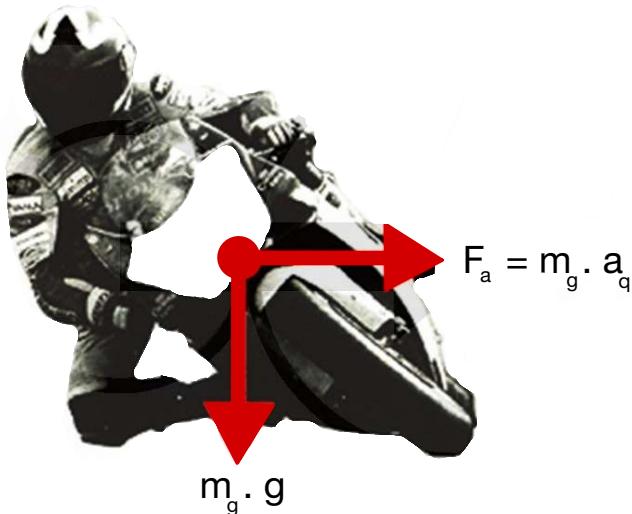


Abbildung 2.8: Vereinfachte Darstellung der Kräfte bei stationärer Kurvenfahrt [Hädrich, 2012]

$$\tan(\lambda) = \frac{F_a}{F_G}$$

$$\lambda = \arctan \left(\frac{F_a}{F_G} \right) \quad (2.1)$$

Kurventechniken

Die bisherigen Überlegungen und Berechnungen beziehen sich jeweils auf den Fall, dass der Fahrer während der Kurvenfahrt in einer Flucht mit der Maschinenachse bleibt. Tatsächlich gibt es jedoch verschiedene Techniken, eine Kurve durchzufahren (Abbildung 2.9).

Der Fahrstil „Drücken“ hat im Vergleich zum Fahrstil „Legen“ keinen Vorteil im Zusammenhang des Grips auf der Straße. Es ist durchaus vorstellbar, dass mit zunehmender Schräglage die Reifenaufstandsfläche (beziehungsweise Reifenlatsch) abnimmt.

Fahrer von Renn- und Supersport-Maschinen bedienen sich der Tatsache des sich verändernden Reifenlatsches und „Hängen“ sich während der Kurvenfahrt von der Maschine. In diesem Fall liegt der Schwerpunkt des Fahrers (SPF) unterhalb des Schwerpunktes der Maschine (SPM), so dass das Motorrad die Kurve mit deutlich geringerer Schräglage durchfahren kann, als beim „Legen“, (Abbildung 2.9). Gegenüber der anderen zwei Schräglagen kann durch das „Hängen“ mit gleichen Schräginkel höhere Seitenkräfte übertragen werden, da hier die Radaufstandsfläche größer ist.

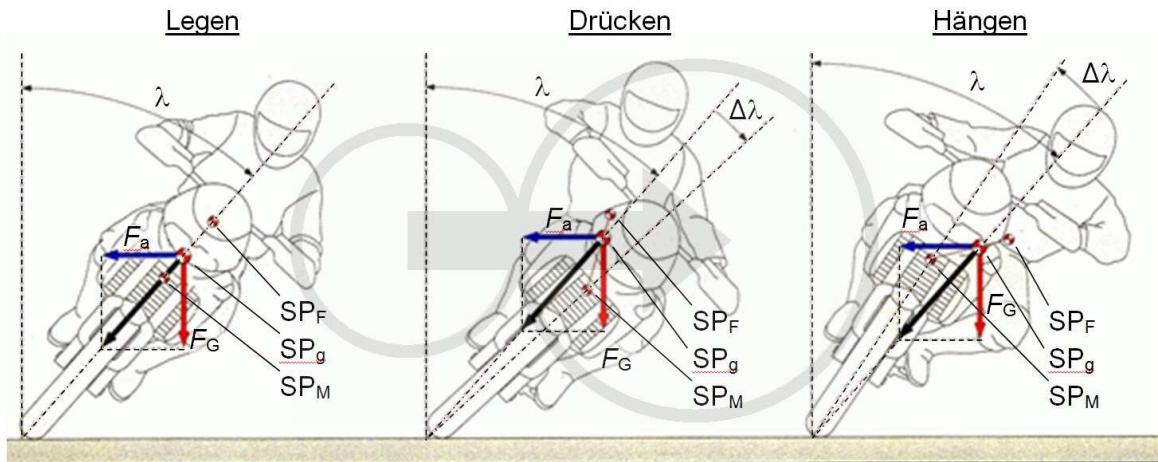


Abbildung 2.9: Verschiedene Techniken bei Kurvenfahrt mit gleicher Geschwindigkeit [Hädrich, 2012]

2.2 Technische Grundlagen

2.2.1 Sensoren und Signale der Smartphones

Die meisten Smartphones haben einen Beschleunigungsmesser und viele enthalten jetzt ein Gyroskop. Je nach Gerät können die softwarebasierten Sensoren ihre Daten entweder vom Beschleunigungs- und Magnetometer oder vom Gyroskop beziehen. Diese Sensoren sind nützlich zum Überwachen von Gerätbewegungen wie Neigung, Schütteln, Drehung oder Schwingen. Die Gerätsbewegung spiegelt normalerweise die direkte Benutzereingabe wider, kann aber auch die physische Umgebung widerspiegeln, in der sich das Gerät befindet. Das Smartphone bewegt sich mit der Person, die es am Körper hat und sich selbst bewegt. [Developers, 2022]

Beschleunigungssensoren

Der Beschleunigungssensor ist ein elektromechanisches Gerät, das die Beschleunigungskraft misst, die durch Bewegung, Schwerkraft oder Vibration verursacht wird. Mathematisch gesehen ist die Beschleunigung ein Maß für die zeitliche Geschwindigkeitsänderung. Der Beschleunigungssensor im Smartphone misst die lineare Beschleunigung des Geräts. In der Ruheposition stellt die Figur die auf das Gerät wirkende Schwerkraft dar und misst gleichzeitig auch die Beschleunigung auf der X- und Y-Achse, die Null sein wird. Die meisten Smartphones verwenden heutzutage Beschleunigungssensoren, um die Bildschirmanzeige abhängig von der Position auszurichten, in der das Gerät gehalten wird. Mit den eingebauten Beschleunigungssensoren können Benutzer unter Anderem ein besseres Anzeigegerlebnis erzielen. [Sharma, 2020] Der Beschleunigungssensor im mobilen Gerät liefert die XYZ-Beschleunigungswerte, die zum Messen der Position und der Beschleunigung des Geräts verwendet werden. Die XYZ-Komposition stellt die Richtung und Position des Geräts dar, an dem eine

Beschleunigung aufgetreten ist. Die vom Gerät bereitgestellten Beschleunigungsmesserwerte enthalten normalerweise auch die Schwerkraft. Das Signal des Beschleunigungssensor wird in die Tief-/Hochpassfilter geleitet, um das Ergebnis basierend auf der verwendeten Anwendung zu verfeinern. [Sathish, 2021]

- Wird das Gerät auf die linke Seite geschoben (bewegt sich also nach rechts), ist der x-Beschleunigungswert positiv.
- Wenn das Gerät auf seinen Boden gedrückt wird, ist der y-Beschleunigungswert positiv.
- Wenn das Gerät mit einer Beschleunigung von Am/s^2 in den Himmel geschoben wurde, ist der Wert der z-Beschleunigung gleich $A+9,81 \text{ m}/\text{s}^2$, da die Schwerkraft ($9,81 \text{ m}/\text{s}^2$) mitberechnet wird.

Im Allgemeinen ist der Beschleunigungssensor ein guter Sensor, wenn die Bewegung des Geräts überwacht werden soll. [Developers, 2022]

Gyroskop

Gyroskop ist ein Gerät, das ein sich schnell drehendes Rad oder einen umlaufenden Lichtstrahl enthält. Gyroskop wird verwendet, um die Abweichung eines Objekts von seiner gewünschten Ausrichtung zu erkennen. Gyroskope werden zur automatischen Lenkung und zur Korrektur der Dreh- und Nickbewegung in Marschflugkörpern und ballistischen Flugkörpern verwendet [Rogers, 2020]. Der Gyroskopsensor in Mikro Elektronisch Mechanischen Systeme (MEMS) ist winzig (zwischen $1 \mu\text{m}$ und $100 \mu\text{m}$). Wenn der Gyro gedreht wird, wird eine kleine Resonanzmasse bei einer Winkelgeschwindigkeitsänderung verschoben. Diese Bewegung wird in elektrische Signale mit sehr geringem Strom umgewandelt, die verstärkt und von einem Host-Mikrocontroller gelesen werden können [sparkfun, 2022]. Viele Smartphones haben einen Gyroskop-Sensor verbaut, der es ermöglicht hat, die lineare Ausrichtung des Handys sehr genau zu bestimmen. Apps können das Gyroskop nutzen, um durch Kippen oder Neigen des Handys beispielsweise ein Spiel zu steuern.[Schanze, 2017]

Global Positioning System (GPS)

GPS besteht aus drei Teilen: Satelliten, Bodenstationen und Empfängern. Die Position der Satelliten ist jederzeit bekannt. Die Bodenstationen verwenden Radar, um sicherzustellen, dass die Satelliten sich tatsächlich dort befinden, wo sie sich befinden sollen. Ein Empfänger in dem Smartphone wartet ständig auf ein Signal von diesen Satelliten und findet heraus, wie weit er von mehreren Satelliten entfernt ist. Sobald die Entfernung zwischen einem Empfänger und vier oder mehr Satelliten berechnet wird, ist genau bekannt, wo der Empfänger sich befindet. Der Basis-GPS-Dienst bietet Benutzern eine Genauigkeit von etwa 7 Metern, 95% der Zeit. GPS-Empfänger zeigen die Geschwindigkeit an und berechnen die Geschwindigkeit mithilfe von Algorithmen im Kalman-Filter.[Nasa, 2019][FAA, 2021][Deiss, 1999]

Table 1 Activity Recognition API Detected Activities

Activity Name	Activity Description
IN_VEHICLE	The device is in a vehicle, such as a car.
ON_BICYCLE	The device is on a bicycle.
ON_FOOT	The device is on a user who is walking or running.
RUNNING	The device is on a user who is running.
STILL	The device is still (not moving).
TILTING	The device angle relative to gravity changed significantly.
UNKNOWN	Unable to detect the current activity.
WALKING	The device is on a user who is walking.

Abbildung 2.10: Ausgaben der Google-Aktivitätserkennung[Elbayoumy, 2018]

2.2.2 Android-integrierte Aktivitätserkennung

Die menschliche Aktivitätserkennung mit kinematischen Sensoren ist einer der weit verbreiteten Forschungsbereiche auf der Basis von Smartphones. Die Entwicklung in der Sensornetzwerktechnologie war die Geburtsstunde der Anwendungen, die intelligente und freundschaftliche Dienste basierend auf der Aktivitätserkennung von Menschen anbieten können. Smartphones sind zu einer wichtigen Technologie geworden und mit leistungsstarken und vielfältigen Sensoren ausgestattet, die zur Aktivitätsüberwachung verwendet werden. [Rasheed u. a., 2015]

In Android-Smartphones hat Google eine Reihe von Application Programming Interfaces (APIs) eingeführt, die es den Entwickler ermöglichen, die Ergebnisse der Erkennung menschlicher Aktivitäten zu erhalten. Dieses API verwendet den eingebauten Sensoren, um zwischen 8 Benutzeraktivitäten zu unterscheiden. Darunter werden „in vehicle“, „on bicycle“, „on foot“, „running“, „still“ und „walking“ erkannt. [Tran u. Phan, 2016][Elbayoumy, 2018]

Die Abbildung 2.10 zeigt einen Ausgabenübersicht der Android-Aktivitätserkennung.

2.2.3 Matlab/Simulink

Matlab ist eine Hochleistungssprache für technisches Rechnen. Matlab integriert Berechnung, Visualisierung und Programmierung in einer benutzerfreundlichen Umgebung, in der Probleme und Lösungen in einer vertrauten mathematischen Notation ausgedrückt werden.

Simulink ist ein grafisches Softwarepaket zur Modellierung, Simulation und Analyse dynamischer Systeme und basiert auf Matlab. Die Software hat sich in den letzten Jahren zum weitesten verbreiteten Softwarepaket in Wissenschaft und Industrie entwickelt. Simulink unterstützt lineare und nichtlineare Systeme, die in kontinuierlicher Zeit, gesampelter Zeit oder einer Mischung aus beiden modelliert sind. Für die Modellierung bietet Simulink eine grafische Benutzeroberfläche (GUI) zum Erstellen von Modellen als Blockdiagramme. Mit dieser Schnittstelle können die gewünschten dynamischen Systeme einfach aufgebaut werden. Mithilfe von Scopes und anderen Anzeigeblocks können die Simulationsergebnisse während der Simulation analysiert werden. Die Simulationsergebnisse können zur Nachbearbeitung und Visualisierung in den Matlab-Arbeitsbereich gestellt werden. [Iov u. a., 2004][Karris, 2008]

Simulink und LabVIEW

LabVIEW ist eine von „National Instruments“ entwickelte Software. Sie wird häufig von Ingenieuren, Wissenschaftlern und Studenten für die Datenerfassung, Instrumentsteuerung und industrielle Automatisierung verwendet. Die LabVIEW-Umgebung besteht aus zwei Hauptkomponenten: Frontpanel (FP) und Blockdiagramm (BD). Ein FP stellt die grafische Benutzeroberfläche bereit, während ein BD die Bausteine eines Systems enthält und einem Flussdiagramm ähnelt. LabVIEW-Systeme werden als virtuelle Instrumente (VIs) bezeichnet und ihr FP erscheint als Instrumententafel, die aus verschiedenen Bedienelementen und Anzeigen besteht.

Ähnlich wie LabVIEW bietet Simulink einen blockbasierten Programmieransatz für die Simulation, den Entwurf und die Analyse dynamischer Systeme. Es bietet eine interaktive grafische Umgebung zusammen mit einer Reihe von Bibliotheken zum Entwerfen und Simulieren von Systemen, einschließlich DSP-Systemen.

Simulink-Blöcke werden als Modelle bezeichnet, und im Gegensatz zu LabVIEW werden die Codeimplementierung und Eingabe-/Ausgabeeinheiten in Simulink nicht explizit unterschieden. Simulink ist in Matlab integriert und kann daher auf die Funktionen und Tools zugreifen, die in der Matlab-Umgebung verfügbar sind. [N. Kehtarnavaz, 2006] [Kasnakoglu, 2015]

Wenn komplexe Simulationen ausgeführt werden sollen oder komplexe Simulationsysteme von Steuerungen oder Anlagen zu erstellen/debuggen sind, wird Simulink verwendet, da LabVIEW keine effizienten Codegeneratoren für die dynamische Simulation hat. Simulink konzentriert sich hauptsächlich auf Simulation und Modellierung, was bei LabVIEW sicherlich nicht der Fall ist.

App-Entwicklung

Die Entwicklung mobiler Apps ist der Prozess zur Erstellung von Software für Smartphones und digitale Assistenten. Die Software kann auf dem Gerät vorinstalliert oder aus einem mobilen App Store heruntergeladen werden. Eine der bekannten Sprachen in der App-Entwicklung ist C. C ist eine leistungsstarke Programmiersprache, mit der Anwendungen in mehreren Bereichen erstellt werden können, von einfachen Taschenrechnern und Apps bis hin zu Videospielen. Sie ist eine Sprache auf niedriger Ebene, dies bietet Geschwindigkeit und eine weitaus bessere Möglichkeit zur Speicherverwaltung.[AWS, 2022][Joy, 2021]

Für die Generierung eines C-Codes aus Simulink-Modellen wird der integrierte C-Coder verwendet.

C/C++-Coder

Der C/C++-Code-Generator wird für Rapid Prototyping, Simulationsbeschleunigung oder einfach als Datei zur Ausführung außerhalb von Matlab und Simulink verwendet. Diese Codegenerierung ist der Prozess der Generierung von Low-Level-Code direkt aus einer High-Level-Programmiersprache oder Modellierungsumgebung.[Mathworks, 2021]

Der C-Coder ist ein weiterer Vorteil von Simulink gegenüber LabVIEW und hierfür ist Simulink die richtige Entscheidung für die Implementierung der Softwares beziehungsweise Algorithmen, die später an Smartphones verwendet werden.

2.3 Mathematische Grundlagen

In dieser Arbeit wird eine Fast-Fourier-Transformation (FFT) eingesetzt, für welche das folgende Hintergrundwissen zum Verständnis benötigt wird.

2.3.1 Fast Fourier Transformation (FFT)

Die „Fast Fourier Transformation“ ist ein wichtiges Messverfahren und wurde erstmals von Cooley und Tukey 1965 diskutiert. Dieses Verfahren wandelt ein Signal in einzelne Spektralkomponenten um und liefert dadurch Frequenzinformationen über das Signal. FFT wird zur Fehleranalyse, Qualitätskontrolle und Zustandsüberwachung von Maschinen oder Anlagen eingesetzt. Dieser Abschnitt erläutert die Funktionsweise einer FFT, die relevanten Parameter und deren Auswirkungen auf das Messergebnis. Die FFT ist ein optimierter Algorithmus zur Umsetzung der „Diskrete Fourier Transformation“ (DFT). Ein Signal wird über einen Zeitraum abgetastet und in seine Frequenzkomponenten zerlegt. Diese Komponenten sind einzelne sinusförmige Schwingungen mit unterschiedlichen Frequenzen, jede mit ihrer eigenen Amplitude und Phase. Diese Transformation ist an einem Beispiel in der Abbildung 2.11 dargestellt.

Das Diagramm zeigt ein kompliziertes Signal im Zeitbereich, das aus der Summe der

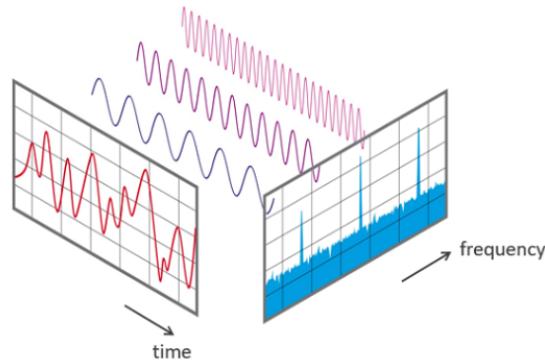


Abbildung 2.11: Beispiel von einer FFT (Zeitbereich und Frequenzbereich)[NTI-Audio, 2019]

drei periodischen Grundsignalen mit unterschiedlichen Frequenzen entsteht. Im Frequenzbereich sind u.A. die einzelne Frequenzen der Grundsignalen dargestellt. Dadurch lässt sich eine FFT-Transformation zwischen dem Zeit- sowie Frequenzbereich grafisch darstellbar.

Schritt für Schritt

Im ersten Schritt wird ein Ausschnitt des Signals abgetastet und zur weiteren Verarbeitung im Speicher abgelegt. Zwei Parameter sind hier relevant:

1. Die Abtastrate f_s des Messsystems (z.B. 48 kHz). Dies ist die durchschnittliche Anzahl von Abtastungen, die in einer Sekunde erhalten werden (Abtastungen pro Sekunde)
2. Die Blocklänge B_L ist die ausgewählte Anzahl von Proben (Samples). Dies ist immer eine ganzzahlige Potenz zur Basis 2 (z.B. $2^{10} = 1024$ Samples)

Aus den beiden Grundparametern f_s und B_L können weitere Parameter der Messung bestimmt werden.

Bandbreite: f_n (= Nyquist-Frequenz). Dieser Wert gibt die theoretische maximale Frequenz an, die durch eine FFT bestimmt werden kann und wird wie folgt berechnet:

$$f_n = \frac{f_s}{2} \quad (2.2)$$

Beispielsweise können bei einer Abtastrate von 100 Hz Frequenzanteile bis maximal 50 Hz bestimmt werden.

Messdauer: D ergibt sich aus der Abtastrate f_s und der Blocklänge B_L wie folgt:

$$D = \frac{B_L}{f_s} \quad (2.3)$$

Frequenzauflösung: d_f gibt den Frequenzabstand zwischen zwei Messergebnissen an und lässt sich mit

$$d_f = \frac{f_s}{B_L} = \frac{1}{D} \quad (2.4)$$

ergeben.

In der Praxis ist die Abtastfrequenz f_s meist eine vom System vorgegebene Größe. Durch die Auswahl der Blocklänge B_L kann jedoch die Messdauer D und Frequenzauflösung d_f definiert werden und es gilt:

- Eine kleine Blocklänge B_L führt zu schnellen Messwiederholungen mit grober Frequenzauflösung.
- Eine große Blocklänge B_L führt zu langsameren Messwiederholungen mit feiner Frequenzauflösung.

Spiegelfrequenzen

Wird die Nyquist-Frequenz (Gleichung 2.2) überschritten, wird das Signal an dieser gedachten Grenze reflektiert und fällt wieder in das Nutzfrequenzband zurück. Diesen unerwünschten Spiegelfrequenzen wird vor der Abtastung mit einem analogen Tiefpassfilter (Anti-Aliasing-Filter) entgegengewirkt. Der Filter sorgt dafür, dass Frequenzen oberhalb der Nyquist-Frequenz unterdrückt werden. [NTI-Audio, 2019][Weisstein, 2022]

2.4 Agile Softwareentwicklung

Das Ziel der agilen Softwareentwicklung ist die kontinuierliche Bereitstellung funktionsfähiger Software, die in schnellen Iterationen erstellt wird. Bei einer agilen Softwareentwicklung werden die Entwicklungsphasen in mehreren Sprints geteilt. Die Länge einer Sprint wird am Anfang festgestellt. Nach jedem Sprint wird das Ergebnis ausgewertet. Dieses wird ggf. für die Anpassung des Entwicklungsvorgehens im nachfolgenden Sprint benutzt. [Brunskill, 2019]

2.5 Unfallerkennungsalgorithmus

In diesem Teil wird der bisherige Unfallerkennungsalgorithmus erläutert und näher betrachtet. Der Algorithmus ist sowohl für Fahrräder als auch für Motorräder entwickelt und bearbeitet die Signale der Beschleunigungssensor sowie Gyroskope im Smartphone und die über GPS gemessene Geschwindigkeit. In dem Unfallerkennungsalgorithmus sind drei Hauptfeatures (Collision, GroundHit und TipOver) eingebaut.

Die Modellierung der Merkmale GroundHit und Collision erfordert weitere unabhängige vorverarbeitete Signale. Zu diesem Zweck wird der Anova-Ansatz (Analysis of Variance) verwendet, um verschiedene statistische Eigenschaften (z. B. Mittelwert, Standardabweichung, Varianz, Integral...usw.) über verschiedene Fenstergrößen der analysierten IMU-Beschleunigungsdaten. Der Anova-Ansatz erfordert, dass die vorverarbeiteten Daten normalverteilt sind. Das Ergebnis der Anova-Analyse liefert die spezifische Energie als optimalen Indikator unter denen aus den untersuchten statistischen Ansätzen zur Klassifizierung der Kollisions- und Bodentreffer-Ereignisse wie folgt:

$$\Delta_{xy,u} e(i) = \left(\int_{i-u}^i a_{Bf,x}(k) dk \right)^2 + \left(\int_{i-u}^i a_{Bf,y}(k) dk \right)^2 \quad (2.5)$$

$\Delta_{xy,u} e$ stellt die Änderung der massenspezifischen kinetischen Energie dar. Es beschreibt ein Ereignis in der XY-Ebene im Zweiradkoordinatensystem (also dem Fahrradrahmen (BF)) während des Zeitfensters u durch die Integration der Beschleunigungssignale $a_{Bf,x}$ und $a_{Bf,y}$. Da Kollisions- und Bodentrefferereignisse nur in dieser Ebene stattfinden, werden die Auswirkungen in der vertikalen z-Achse auf die Fahrbahnoberfläche oder Sprünge des Zweiradsystems zurückgeführt. Zusätzlich bietet die Varianz der x- und y-Beschleunigungssignale über ein Zeitfenster weitere Trennmöglichkeiten für GroundHit-Ereignisse. [Schnee u. a., 2021]

Die Entwicklung des Unfallerkennungsalgorithmus sowie das Pocket-Mode wird mittels der agilen Methode erfolgt. Der implementierte Algorithmus enthält einen verbreiteten und komplexen Entscheidungsbaum, welcher sich mit Simulink sowohl übersichtlicher als auch einfacher darstellen lässt als mit LabVIEW. Die Signale aus dem Smartphone weisen keine Fahrtrichtung zu und müssen je nach Position unterschiedlich bearbeitet werden. Bevor die Signale zur Entscheidung verarbeitet werden, ist eine Kalibrierung notwendig.

2.5.1 Kalibrierung

Die Kalibrierung dient dazu, die Ausrichtung des Motorrads zu erkennen, damit die Richtung der Fahrt sowie diesbezügliche Bewegungen (Beschleunigung, Bremsen, Neigung, ...usw.) richtig erkannt und gut ausgewertet werden.

In der Abbildung 2.12 ist der Unterschied zwischen den originalen Achsenrichtung (vom Smartphone) und diesen des Objekts anhand eines Fahrradbeispiel abgebildet. In der Abbildung sind die Achsen des Smartphones mit den Ziffern „SF“ (Sensor Frame) vermerkt, sowie diese des Fahrrads mit den Ziffern „BF“ (Bike Frame). Während der Kalibrierung wird der Stand des Fahrrads beziehungsweise Motorrads sowie die Richtung der Fahrt erkannt und die gesammelten Daten aus dem Smartphone so umgerechnet, dass sie fürs Koordinatensystem des Motorrads (BF) geeignet sind. Nachdem der Benutzer die App zum ersten Mal installiert, kalibriert sich der Algorithmus während der ersten Fahrt. Sollte der Benutzer die Lage des Smartphones

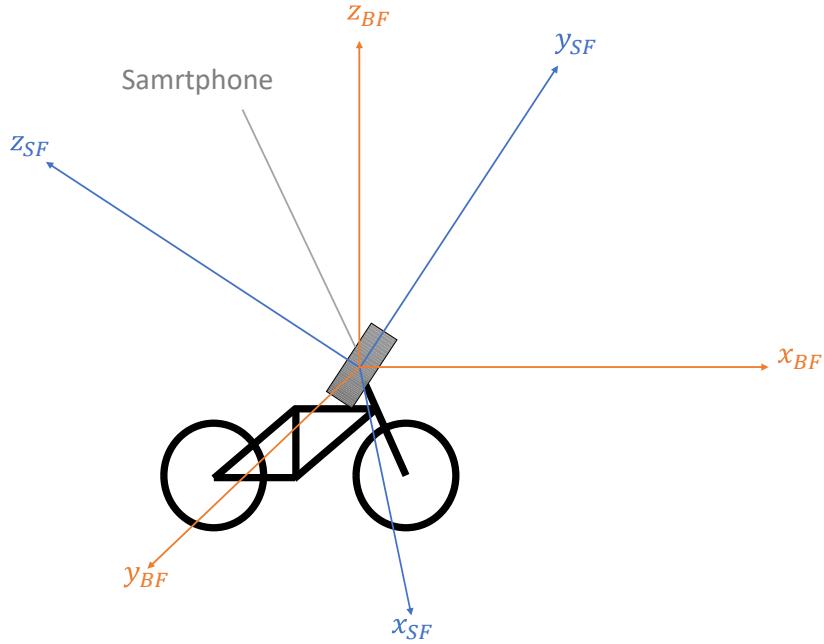


Abbildung 2.12: Achsenrichtung in Sensorframe sowie in Bikeframe

nachträglich ändern, kalibriert sich der Algorithmus langsam nach. Die Nachkalibrierung erfolgt langsamer als die Erstkalibrierung, damit die Unfälle durch eine schnelle Nachkalibrierung nicht übersehen werden.

2.5.2 Übersicht der bereits erkennbaren Unfälle

In der Abbildung 2.13 ist der Entscheidungsbaum abgebildet, wonach eine Unfallklassifizierung erfolgt wird. Die Einzelfeatures (Collision, GroundHit, TipOver) werden später separat erläutert.

Durch die Kombination der verschiedenen Parameterwerten lässt sich eine Unfallklasse ergeben. Die Klasse gibt die Aussage, ob ein Unfall tatsächlich passierte, und entspricht ebenfalls einer geschätzte Unfallschwere. Ein Unfall mit einer starken Kollision hat eine andere Klassifizierung als dieser mit einer leichten Kollision, wenn die anderen Parameter gleich bleiben. Die verschiedene TipOver-Möglichkeiten (Umkippen) unterscheiden zwischen einem seitlichen und frontalen Umkippen, was ebenfalls zu verschiedener Klassifizierung führen kann. Eine GroundHit-Erkennung könnte (vor Allem bei einem leichten Aufprall) zum Entscheidungsunterschied führen.

Die Abbildung 2.14 beinhaltet die Klassifizierung für jede der vier Komponenten im Entscheidungsbaum sowie deren Bedeutung.

2.5.3 1. Feature: TipOver

Diese Komponente prüft den Neigungswinkel des Motorrads und stellt fest, wenn das Motorrad umkippt.

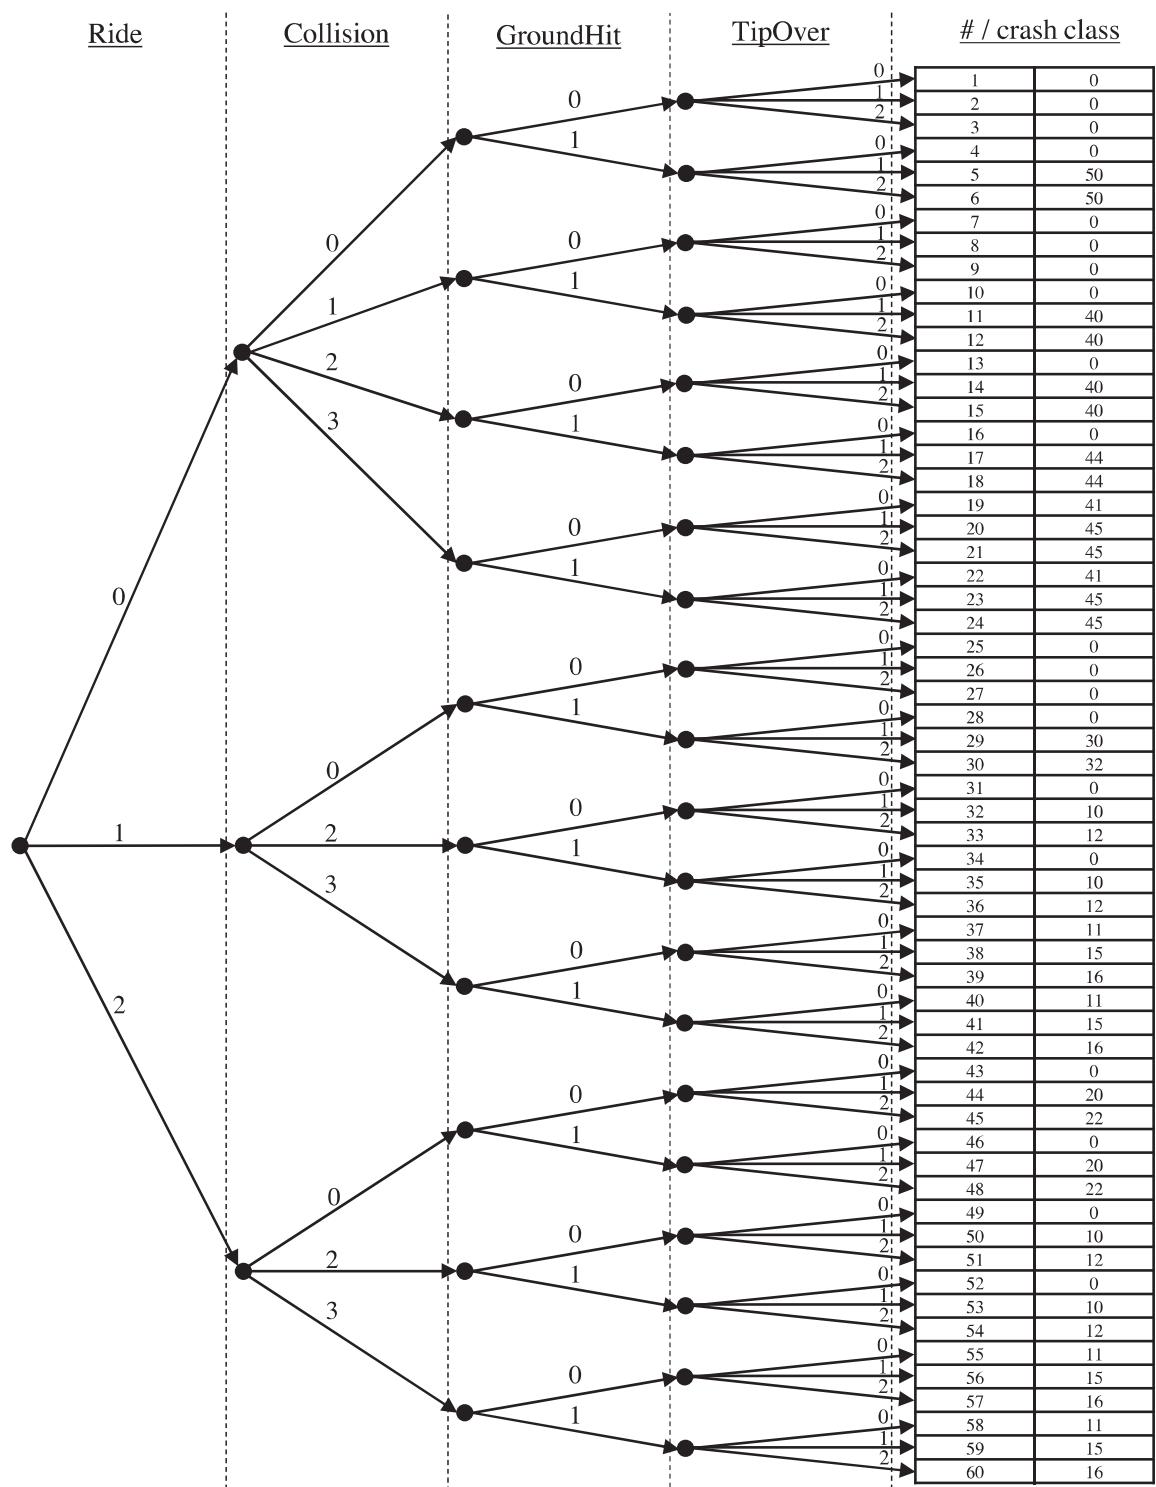


Abbildung 2.13: Entscheidungsbaum des Unfallerkennungsalgorithmus anhand der drei Features sowie des Fahrzustands [Schnee u. a., 2021]

Table 1

Definition of bicycle crash features and polytomous states.

#	Name	Description	States
1	Ride (Rd)	riding state, right before accident	0: standing 1: starting/stopping 2: riding
2	Collision (C)	collision with a rigid obstacle or further party involved	0: no collision 1: soft collision 2: medium collision 3: strong collision
3	GroundHit (GH)	impact when a bicycle is tipping over	0: false, 1: true
4	TipOver (TO)	orientation of bicycle, bicycle rolled over bicycle rotates over the handlebar	0: upright bicycle 1: TipOver (RollOver) 2: NoseOver

Abbildung 2.14: Erklärung der verschiedenen Features-Zustände im Entscheidungsbaum in der Abbildung 2.13 [Schnee u. a., 2021]

Bei Motorradunfällen auf Straßen, die sich im Anschluss an eine Kurve ereignen, stellt sich immer wieder die Frage nach der maximalen Geschwindigkeit, mit der die Kurve auf einem Motorrad durchfahren werden konnte. Um das Motorrad durch die Kurve zu bewegen, muss sich der Fahrer mit seiner Maschine in die Kurve legen. Während einer Kurvenfahrt wirken zwei Kräfte (F_q) und (F_G) am Motorrad (Abbildung 2.8). Wenn die Kraft (F_q) größer als (F_G) tritt, kippt das Motorrad um. Im normalen Fall soll

$$F_G \geq F_q$$

immer gültig sein. D.h.

$$\frac{F_q}{F_G} \leq 1$$

Beim Einsetzen in der Gleichung 2.1 ergibt sich der maximale zulässige Winkelwert:

$$\lambda_{zul} \leq \arctan(1) \leq 45^\circ$$

D.h. Bei einer Neigung von über 45° , sollte das Motorrad umkippen. Sollte der Fahrer das Fahrstil „Hängen“ verwenden, könnte er eine größere Neigung erfolgen, ohne zu rutschen.

Das Model „TipOver“ erkennt den Fall, in dem der Winkel über den Schwellwert liegt, und gibt dem Entscheidungsmodell eine Meldung weiter.

2.5.4 2. Feature: GroundHit

Dieses Model dient dazu, den Schlag zu erkennen, wenn das Motorrad am Boden ankommt. Dieses Model geht von der kinetischen Energie aus der Gleichung 2.5 aus. Es hat einige Spezifikationen, die die verschiedene Szenarien abdeckt. Zwei typische Szenarien sind in der Abbildung 2.15 dargestellt. Die Abbildung 2.15a zeigt der Fall, wenn ein Fahrrad nach einer ursprünglichen aufrechten Position umkippt, und die Abbildung 2.15b das Umkippen eines Fahrrads mit einer ursprünglichen Neigung (z.B. in einer Kurve). Die Energie vom GroundHit im zweiten Fall ist deutlich kleiner, deswegen wird der Schwellwert nach dem Neigungswinkel ebenfalls angepasst. Je größer die Motorradneigung ist, desto kleiner ist der GroundHit-Schwellwert.

Nachdem das Model den Bodenschlag erkennt, wird eine Meldung dem Entscheidungsmodell weitergegeben. Demnächst werden zwei Beispiele zum besseren Verständnis erläutert.

Beispiele 1: Kein GroundHit

In diesem Beispiel ist eine Testfahrt ohne GroundHit durchgeführt und schließlich analysiert. Nach der Fahrt und bei späterer Simulation wurde entdeckt, dass die Kalibrierung nicht richtig war und musste manuell in der Simulation angepasst werden.

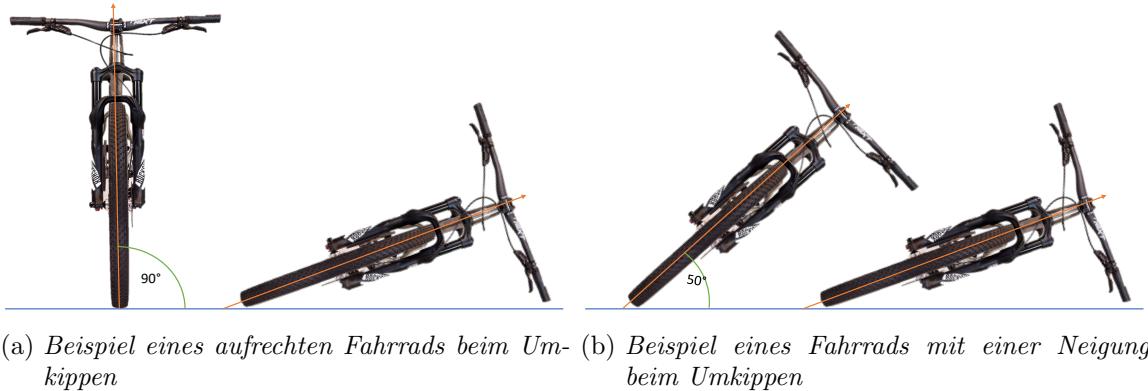


Abbildung 2.15: Beispiel eines Fahrrads beim Umkippen mit einer ursprünglichen aufrechten Position sowie Neigung

Eine Rotationsmatrix, die in der Regel durch die Kalibrierung gerechnet und umgesetzt wird, wurde hier manuell erstellt und verwendet. Um eine falsche Nachkalibrierung zu verhindern, wurde der dafür zuständige Teil deaktiviert. Es ist wichtig zu wissen, dass die Position des Geräts sich während der Fahrt kaum verändert hat.

In der Abbildung 2.16 ist der Fall vorgestellt. Während dieser Fahrt fand ebenfalls kein Unfall statt. Die oberen Grafiken zeigen die Geschwindigkeit (blau) sowie die GroundHit-Auslösungen aus dem Feld (grün) oder aus der Simulation (orange) über die Zeit. Die unteren Grafiken stellen die kinetische Energie (blau) aus der Gleichung 2.5 sowie den Energieschwellwert (orange) über die Zeit dar. Die zwei rechte Grafiken veranschaulichen einen kleinen kritischen Bereich der jeweiligen Signalen, damit der Signalverlauf an der Stelle klar betrachtet wird.

An dieser Stelle hat die tatsächliche Energie (blau) den Schwellwert (orange) nicht überschritten, was eigentlich keinen GroundHit-Alarm auslösen soll. Während der Fahrt hat das Smartphone an der Stelle einen falschen Alarm ausgelöst, da die Kalibrierung nicht 100% richtig war. In den simulierten Daten wurde diese angepasst und hat dazu geführt, keinen Unfall zu erkennen.

Beispiele 2: Unfall mit GroundHit

In der Abbildung 2.17 sind die Daten eines Unfalls mit einem erkannten GroundHit dargestellt und auf die Unfallphase gezoomt. Die oberen Grafiken stellen die Geschwindigkeit (blau) sowie die GroundHit-Auslösung (orange) über die Zeit dar. Die unteren Grafiken zeigen die kinetische Energie (blau) aus der Gleichung 2.5 sowie den Energieschwellwert (orange) im Laufe der Zeit. Die zwei rechte Grafiken veranschaulichen einen kleinen Bereich der jeweiligen Signalen, in dem einen Unfall aufgetreten ist.

In der Abbildung ist zu erkennen, dass der Energieschwellwert bei der Sekunde 591 stark sinkt, da an dieser Stelle der Neigungswinkel ebenfalls größer wird. Der Wert wird an dieser Stelle von der tatsächlichen kinetischen Energie überschritten, was eine Alarmauslösung feuern muss. Die obere rechte Grafik zeigt die Auslösung an der gleichen Stelle, an der den Schwellwert überschritten wird.

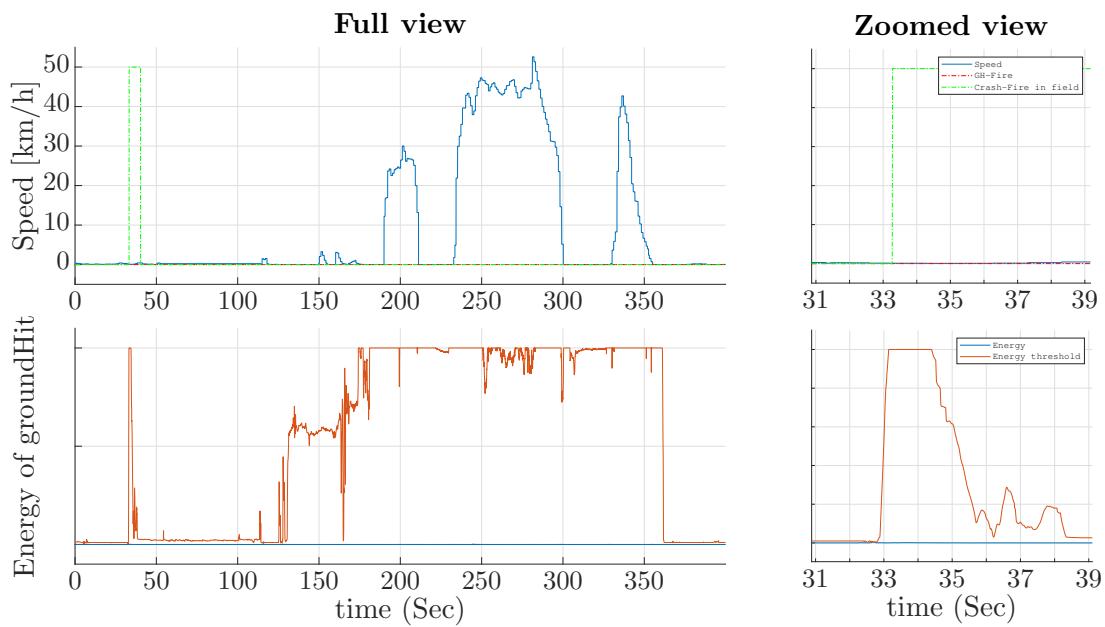


Abbildung 2.16: Verlauf der Energie sowie des Energieschwellwerts bei einer Testfahrt ohne GroundHit

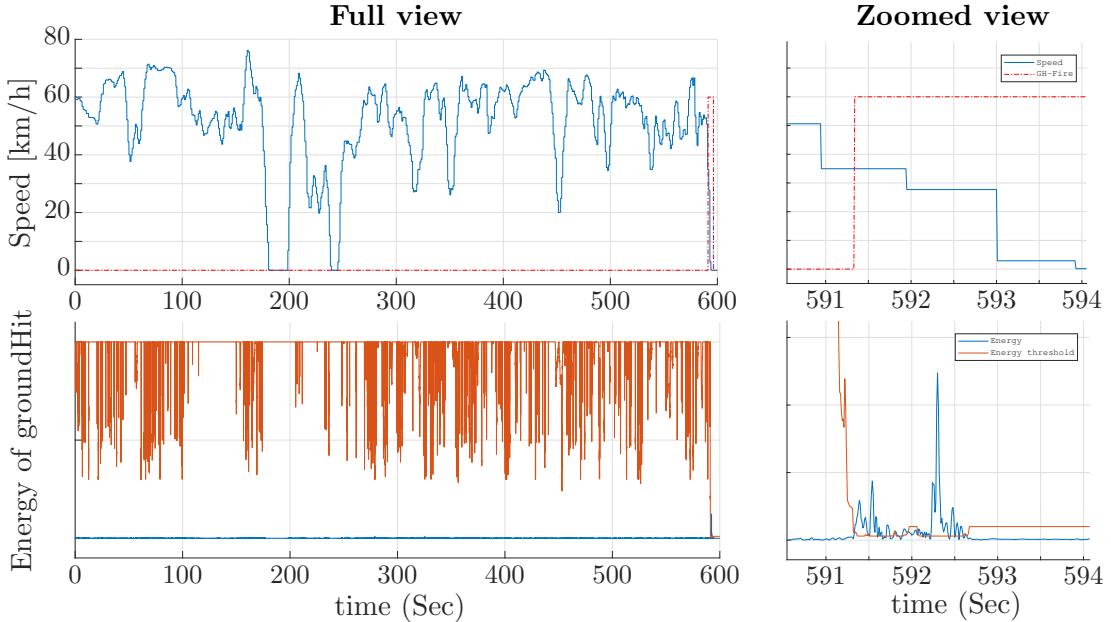


Abbildung 2.17: Verlauf der Energie sowie des Energieschwellwerts bei einer Echtfahrt mit GroundHit

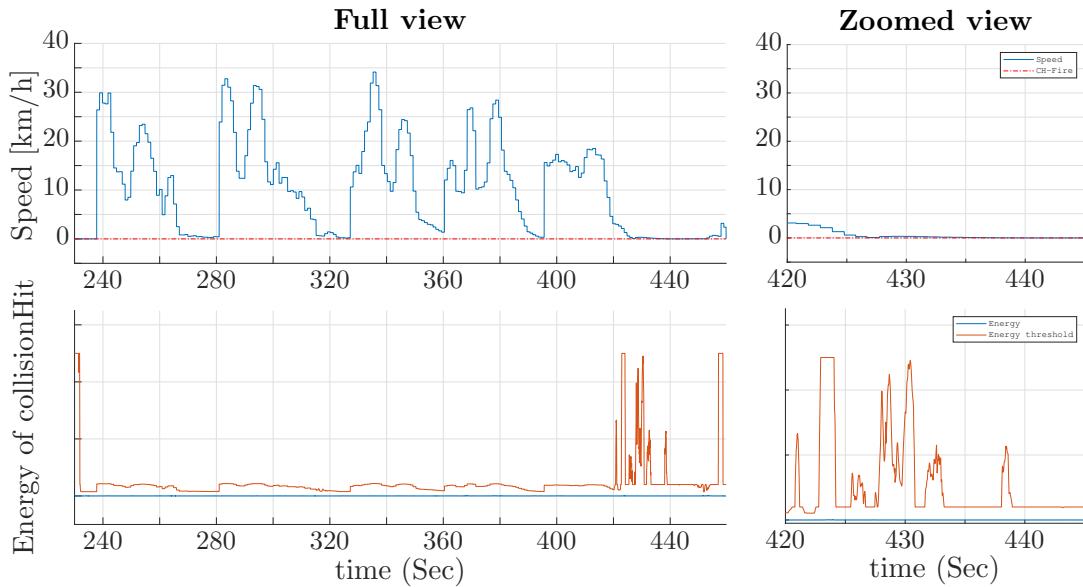


Abbildung 2.18: Verlauf der Energie sowie des Energieschwellwerts bei einer echten Fahrt ohne Kollision

2.5.5 3. Feature: Collision

Dieses Feature dient dazu, eine Kollision zu erkennen. Es geht ebenfalls von der kinematischen Energie (Gleichung 2.5) aus und hat vier mögliche Stufen, die in Abbildung 2.14 bereits erklärt wurden. Es ist allerdings wichtig zu wissen, dass der Kollisionsschwellwert von der Geschwindigkeit, die zu den Schwellwert umgekehrt proportional ist, und Neigungswinkel des Motorrads beeinflusst wird.

In der Abbildung 2.18 ist der Fall vorgestellt, in dem keine Kollision erkannt wurde. Während dieser Fahrt fand ebenfalls kein Unfall statt. Die oberen Grafiken zeigen die Geschwindigkeit (blau) sowie die Collision-Auslösung (orange) über die Zeit. Die unteren Grafiken stellen die kinetische Energie (blau) sowie den Energieschwellwert (orange) über die Zeit dar. Die zwei rechten Grafiken veranschaulichen einen kleinen Bereich der jeweiligen Signalen, wo eine Überschneidung der Signalen nicht klar ist, um diese besser erkennbar zu machen.

Aus der Grafiken ist zu bemerken, dass der Schwellwert der Energie nicht überschritten wird, auch wenn er stark sinkt. Das entspricht ebenfalls den Erwartungen.

Analog dazu ist in der Abbildung 2.19 der Fall vorgestellt, in dem eine Kollision erkannt wurde. Während dieser Fahrt fand ebenfalls ein Unfall statt. In der Grafik ist eine Kollision-Alarmauslösung bei der Sekunde ca. 590 s sichtbar. Die rechten Grafiken zeigen die Kollisionsstelle im Signal genauer an und lässt die Überschneidung des Schwellwert durch die tatsächliche Energie sich gut veranschaulichen. An der Stelle, wo die Überschneidung geschehen ist, findet eine Alarmauslösung statt, was ebenfalls die Erwartungen entspricht.

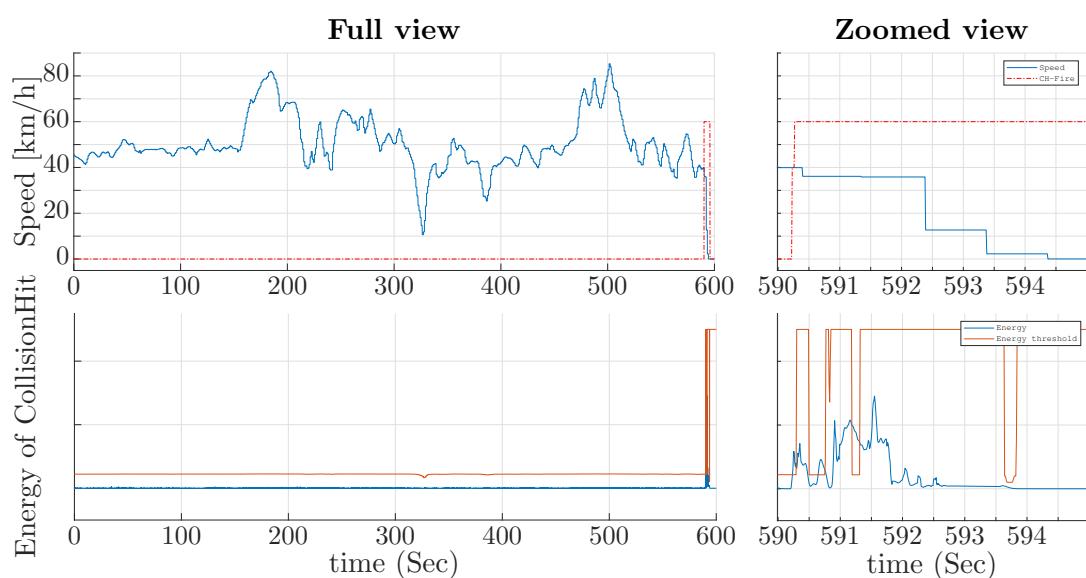


Abbildung 2.19: Verlauf der Energie sowie des Energieschwellwerts bei einer echten Fahrt mit einer Kollision

3 Unfallerkennung im Pocket-Mode

Dieses Kapitel beschäftigt sich mit der Weiterentwicklung der Unfallerkennung im Taschenmodus und mit der Implementierung neuer Funktionen sowie die Verifizierung dieser Änderungen. Es wird zuerst erwähnt, warum ein Pocket-Mode wichtig ist und welche Szenarien im Vergleich zum originalen Unfallerkennungsalgorithmus Unterschied machen würden. Schließlich werden ein Paar Szenarien näher betrachtet und Verifikationsversuche geplant, durchgeführt und abschließend ausgewertet werden.

3.1 Grund des Pocket-Modes

Die Anzahl der App-Nutzer (Unfallerkennungsalgorithmus) lag im November 2021 bei ca. 1190. Die Anzahl der zugelassenen Motorräder zum gleichen Zeitraum betrugt in Deutschland ca. 4,6 Millionen. Um die Anzahl der App-Nutzer zu erhöhen, sollten die Bedürfnisse der Benutzern bekannt sein, damit diese durch erweiterte beziehungsweise neue Funktionen abgedeckt werden.

In diesem Sinne wurde eine Umfrage vom Spiegel-Institute im Auftrag von Bosch Help Connect im Zeitraum zwischen November und Dezember 2021 in vier Länder (Deutschland, Frankreich, Italien, Spanien) mit jeweils 333 Befragten durchgeführt.

Die zwei wichtigsten relevanten Fragen waren:

- Wofür nutzen Sie Ihr Smartphone während einer Fahrt mit dem Motorrad?
- Wo befindet sich aktuell Ihr Smartphone während der Fahrt normalerweise?

Die Ergebnisse der Umfrage aus den vier Ländern lagen sehr nah zu einander, deswegen wird demnächst nur das Umfrageergebnis der deutschen Nutzern erläutert.

In der Abbildung 3.1 ist das Ergebnis der Umfrage aus dem deutschen Markt dargestellt. 47% der Befragten nutzen kein Smartphone während einer Fahrt, weil die Strecke bekannt ist oder weil sie Ihre Smartphones nicht am Lenker befestigen wollen. 70% der Befragten haben Ihre Handys nicht am Motorrad oder am Lenker gehabt sondern in der (Hosen-)Tasche beziehungsweise im Rucksack.

Aus diesem Grund ist die Entwicklung einer Unfallerkennung im Pocket-Mode wichtig, um das Smartphone nicht mehr unbedingt am Lenker befestigt werden zu müssen. Die Weiterentwicklung der Unfallerkennung wird mit agilen Methoden erfolgt.

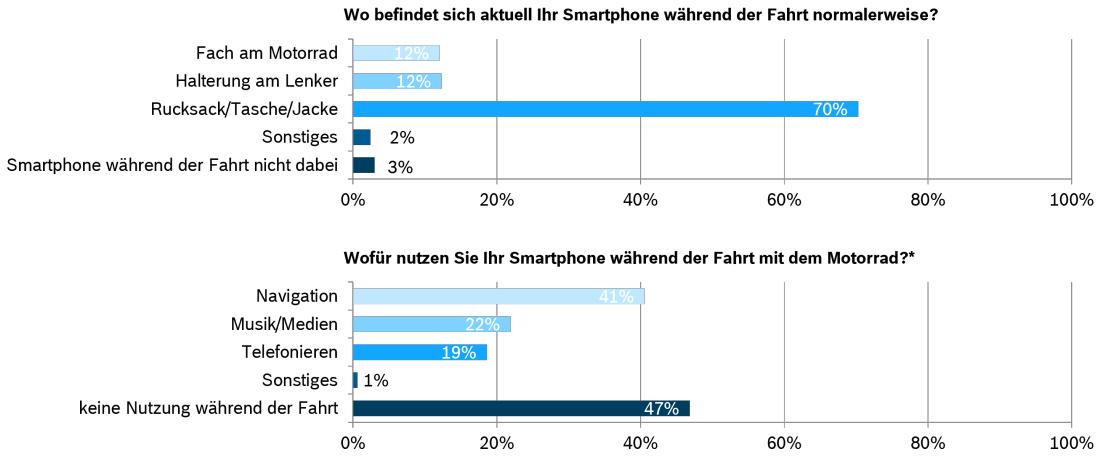


Abbildung 3.1: Ergebnisse der Umfrage vom Spiegelinstiute über das Taschenmodus

3.2 Kritische Szenarien

Im Abschnitt 2.5 ist der Ablauf der aktuellen Unfallerkennungsalgorithmen sowie deren Parameter (z.B. TipOver) erläutert. Die Entwicklung des Pocket-Modes sollte auf keinen Fall zu Konflikten mit dem normalen Modus führen. Die bisherige Zuverlässigkeit des Algorithmus darf ebenso durch das Pocket-Mode nicht verringert werden, in dem ein im normalen Modus gut erkennbares Unfallszenario durch das Pocket-Mode übersehen wird.

Um solche Konflikte zu vermeiden, wird eine Liste der Use- sowie Edgecases vorbereitet, in der die Erwarteten Reaktion des aktuellen Algorithmus zum jeweiligen Szenario aufgelistet wird. Dadurch erfolgt eine Übersicht der möglichen Konflikten sowie der Fällen, wo ein falscher Alarm ausgelöst werden könnte, und gleich eine mögliche Gegenmaßnahme.

Die Abbildung 3.2 zeigt die Liste. Die Spalte „Szenario“ enthält eine allgemeine Beschreibung des Szenarios, das auch unterteilt wird. In der Spalte „Beschreibung“ ist eine nähere Erklärung des Szenarios erläutert. Da das Verhalten des Smartphones in der Hosentaschen (am Oberschenkel) und am Oberkörper unterschiedlich sein könnte, werden diese separat betrachtet. Die Spalte „Erkennung durch den Algo“ berichtet, ob der aktuelle Algorithmus das entsprechende Szenario richtig erkennen wird (IO: In Ordnung, NIO: Nicht In Ordnung). Unter „Bemerkungen“ ist eine weitere Erklärung des erwarteten Ergebnisses beschrieben. Unter der Bewegung des Oberkörpers fallen verschiedene Möglichkeiten, z.B. seitliches Lehnen, was der Algorithmus problemlos erkennen würde und keine falsche Alarme auslöst.

Bei den kritischen Szenarien, wo der Algorithmus den Fall nicht richtig erkennen würde, ist eine mögliche Gegenmaßnahme zum Korrigieren der Algorithmus-Entscheidung aufgeschrieben. Einige Szenarien (z.B. Auf der Fußraste während einer Fahrt zu stehen) sollen ausführlich getestet werden, um die richtige Reaktion des Algorithmus zu analysieren und gegebenenfalls eine Gegenmaßnahme einzuplanen.

ID	Szenario-Name	Beschreibung	Algo-Reaktion (Erwartungen)		Bemerkungen	Mögliche Gegenmaßnahmen
			Handy am Körper	Handy am Motorrad		
1	Oberkörper bewegen	Umdrehen, Nach hinten schauen, Lenker mit einer Hand halten	-	IO	Kein Einfluss auf das Handy	-
2			IO	-	Kein GH, keine CH, Nur geringe Winkeländerung um die X-Y-Achsen	-
3		Nach vorne und hinten lehnen	IO	-	Kein Einfluss auf das Handy	-
4			IO	-	Kein GH, keine CH, Keine kritische Winkeländerung um die X-Y-Achsen	-
5		Seitliches Lehnen (rechts und links)	-	IO	Kein Einfluss auf das Handy	-
6			IO	-	Kein GH, keine CH, Keine Winkeländerung um die Z-Achse	-
7	Ab- und Aufsteigen		-	IO	Kein Einfluss auf das Handy	-
8			NIO	-	Bewegungsabhängig, enthält Winkeländerung (TO) und manchmal GroundHit. Falsch positiv bei GH, Kein GH -> kein Unfall	Testen
9	Laufen	Handy am Körper	NIO	-		
10	Handy in der Hand nehmen/nutzen	Eintippen, telefonieren, bewegen...etc.	NIO	-	Alles möglich (GH, CH, TO)	Lauferkennungsmodul einbauen und die Unfallerkennung während des Laufen deaktivieren
11	Wheelie fahren	Nur auf das Hinterrad fahren	IO	-	Extremer Fall (Not intended use)	Erkennung durch das phone-lifting-Funktion
12	Auf der Motorradstützbank stehen	-	IO	-	Extremer Fall (Not intended use)	In AGB ausschließen
13	Auf dem Motorrad (Fußraste) stehen	Stehend fahren	-	IO	-	In AGB ausschließen
14	Anhalten	Fahren, dann (stark) bremsen und Fuß runter	-	IO	Kein Einfluss auf das Handy	Testen
15			IO	-	Kein GH, keine CH, Keine kritische Winkeländerung um die X-Y-Achsen	-
16	Normales Fahren	Beschleunigen, bremsen, Kurven fahren... ect.	-	IO	Im aktuellen Algo abgedeckt	
17	Handy in der Tasche rutscht	Mit Winkeländerung	-	NIO	Fahren und Winkeländerung -> Unfall	Schnelles Nachkalibrierung oder in AGB bekannt machen (Handy befestigen)
18		Keine Winkeländerung (gleiche Position)	-	IO	Keine Winkeländerung -> kein Unfall	Testen ob GH oder CH erkannt werden
19	Motorrad abstellen	-	-	IO	Im aktuellen Algo abgedeckt	-
20	Hanging off	In der Kurve (Hanging off)	-	IO	Keine ausreichende Winkeländerung für ein TipOver	

Abbildung 3.2: Die Use- und Edgecases mit der erwarteten Reaktion des Algorithmus

Nach einer internen Statistik ist das Laufen ein häufiger Grund von den falschen Alarmauslösungen, deswegen ist eine Lauferkennung zur Verbesserung der Zuverlässigkeit sehr wichtig.

3.3 Lauferkennung

In der bereits bestehenden Version des Algorithmus ist davon ausgegangen, dass das Smartphone am Lenker befestigt wird. Wenn die Person das Handy nach einer Fahrt in die Hosen- beziehungsweise Jackentasche einsteckt und fängt an zu laufen, wird öfters einen falschen Alarm (falsch-positiv) ausgelöst, da das Laufen im bisherigen Algorithmus nicht berücksichtigt wurde. Wenn die Unfallerkennung im Pocket-Mode verwendet wird, ist stark zu erwarten, dass die Person nach einer Fahrt oder während einer Pause (z.B. Tankpause) vergisst (oder ignoriert), die Unfallerkennung zu deaktivieren, und mit dem Smartphone an sich läuft. Das führt dazu, dass die Anzahl der falschen Alarmanlagen im Pocket-Mode wesentlich steigt.

Diese Arbeit beschäftigt sich im Teil mit der Implementierung der Lauferkennung. Das Ziel dahinter ist das Laufen zu erkennen und die Unfallerkennung temporär zu deaktivieren, damit die falsche Alarne verhindert werden. In diesem Kapitel werden die Entwicklungsschritte der Lauferkennung erläutert.

In der Abbildung 3.3 ist ein Beispieldaten aus dem Beschleunigungssensor im Smartphone während des Laufens abgebildet. Die Person kann bis zu zwei Schritte pro Sekunde im Schnitt zurücklegen. In der Grafik können die Peaks innerhalb einer Sekunde aufgezählt werden und die durchschnittliche Anzahl der Schritte kann ermittelt werden. Wenn diese unter zwei pro Sekunde liegt, ist vom Laufen auszugehen, da ein Motor so wenige Umdrehungen pro Sekunde nicht schafft. Im nächsten Abschnitt werden diese Peaks aufgezählt, um die Anzahl der Schritte beziehungsweise Umdrehungen zu ermitteln.

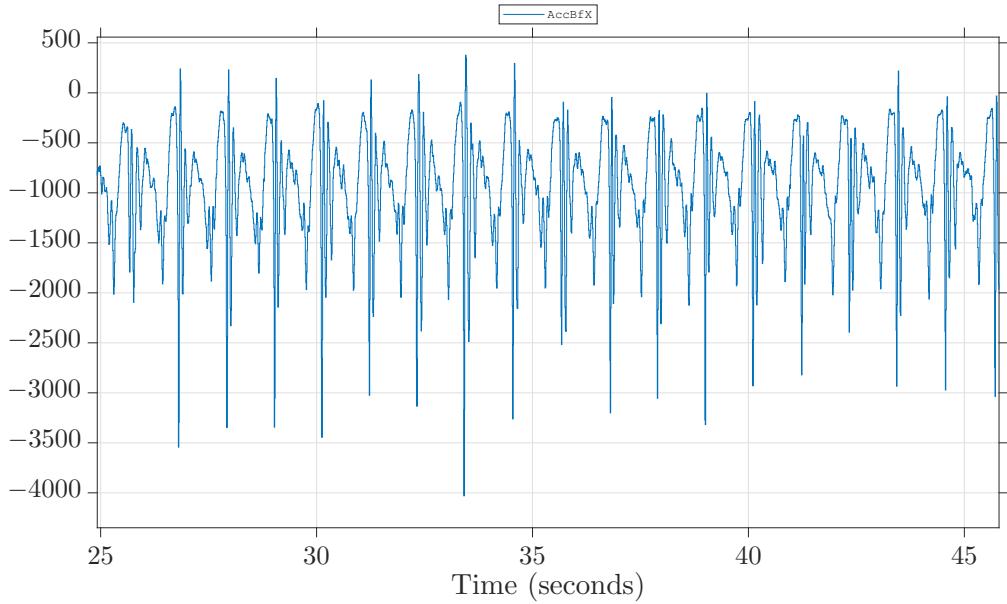


Abbildung 3.3: Beispiel eines Beschleunigungssignal beim Laufen

3.3.1 Spitzenzähler

Wie bereits erwähnt wurde, kann die Person bis zu zwei Schritte pro Sekunde laufen. D.h. aus einem typischen Laufsignal (z.B. Abbildung 3.3) soll maximal zwei Schritte pro Sekunde aufgezählt werden. Es soll ein System implementiert werden, das die Anzahl der Schritte beziehungsweise Spitzen aufzählt und der Mittelwert pro Sekunde zurückgibt. Zur Vereinfachung der Implementierung wird eine Simulink-Testumgebung (Abbildung 3.4) aufgebaut, in der ein bekanntes Sinussignal generiert, dargestellt und verarbeitet wird. Das generierte Sinussignal hat eine Amplitude von 325 und eine Frequenz von 100 Hz und lässt sich mithilfe eines Scopes (Simulink-Block) in der Abbildung 3.5 (blau) darstellen sowie wie oft das Signal die x-Achse überschneidet (rot). Aus der Grafik ist die Anzahl der Peaks einfach zu ermitteln und diese beträgt in diesem Fall 100 Hz umgerechnet.

Die Abbildung 3.4 zeigt eine Testumgebung, in dem zwei Methoden zum Spitzenzähler implementiert wurden.

In der ersten (oberen) Methode wird die Funktion „Zero Crossing“ verwendet. Diese zählt wie oft das Signal die x-Achse überquert. Dieses Model liefert das richtige erwartete Ergebnis, wenn das Signal um die x-Achse dargestellt ist, und hilft allerdings nicht, wenn das Signal ein Offset hat (Verschiebung auf der y-Achse), da in diesem Fall das Signal die x-Achse je nach der Amplitude nicht mehr überschneidet. Das führt dazu, dass das Ergebnis nicht mehr zuverlässig ist.

Eine zweite Methode hat sich ergeben, dass die Funktion „Counter up“ in dem Model verwendet wird. Dieses Block zählt wie oft das Signal in die positive Richtung geht. Die neue Implementierung hat ein zuverlässiges Ergebnis im Vergleich zum vorherigen Model geliefert.

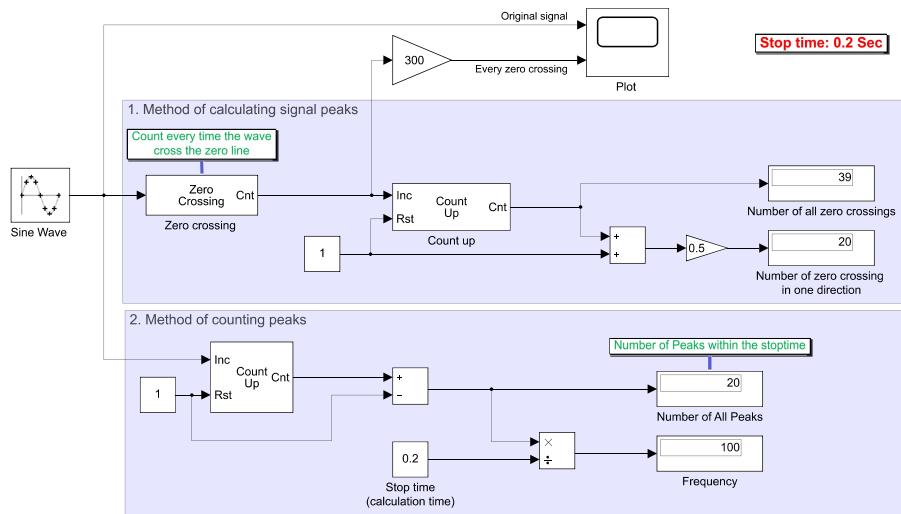


Abbildung 3.4: Testmodell der Lauferkennung - Spitzenzähler

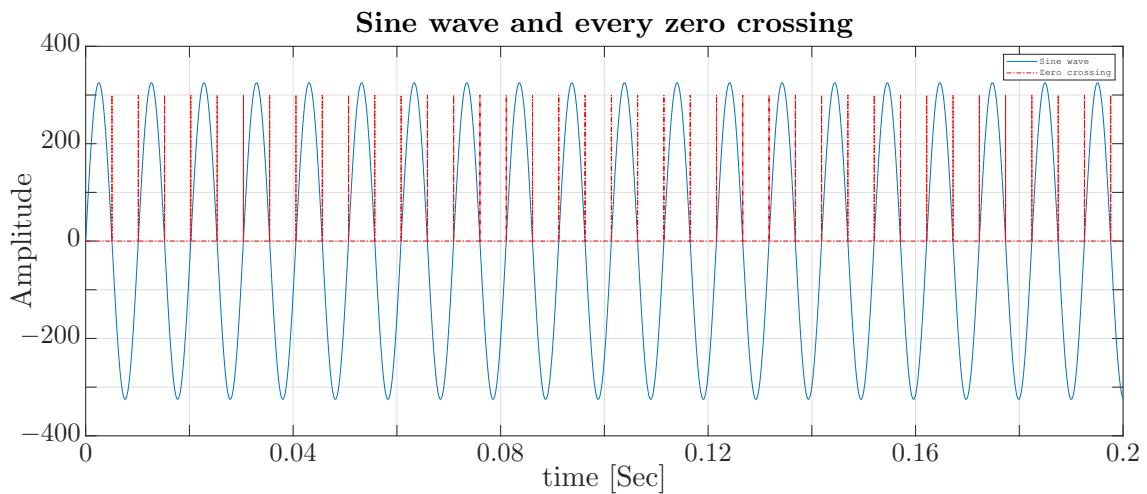


Abbildung 3.5: Darstellung des im Testmodell der Lauferkennung generierten Sinussignal sowie jede Überschneidung der x-Achse

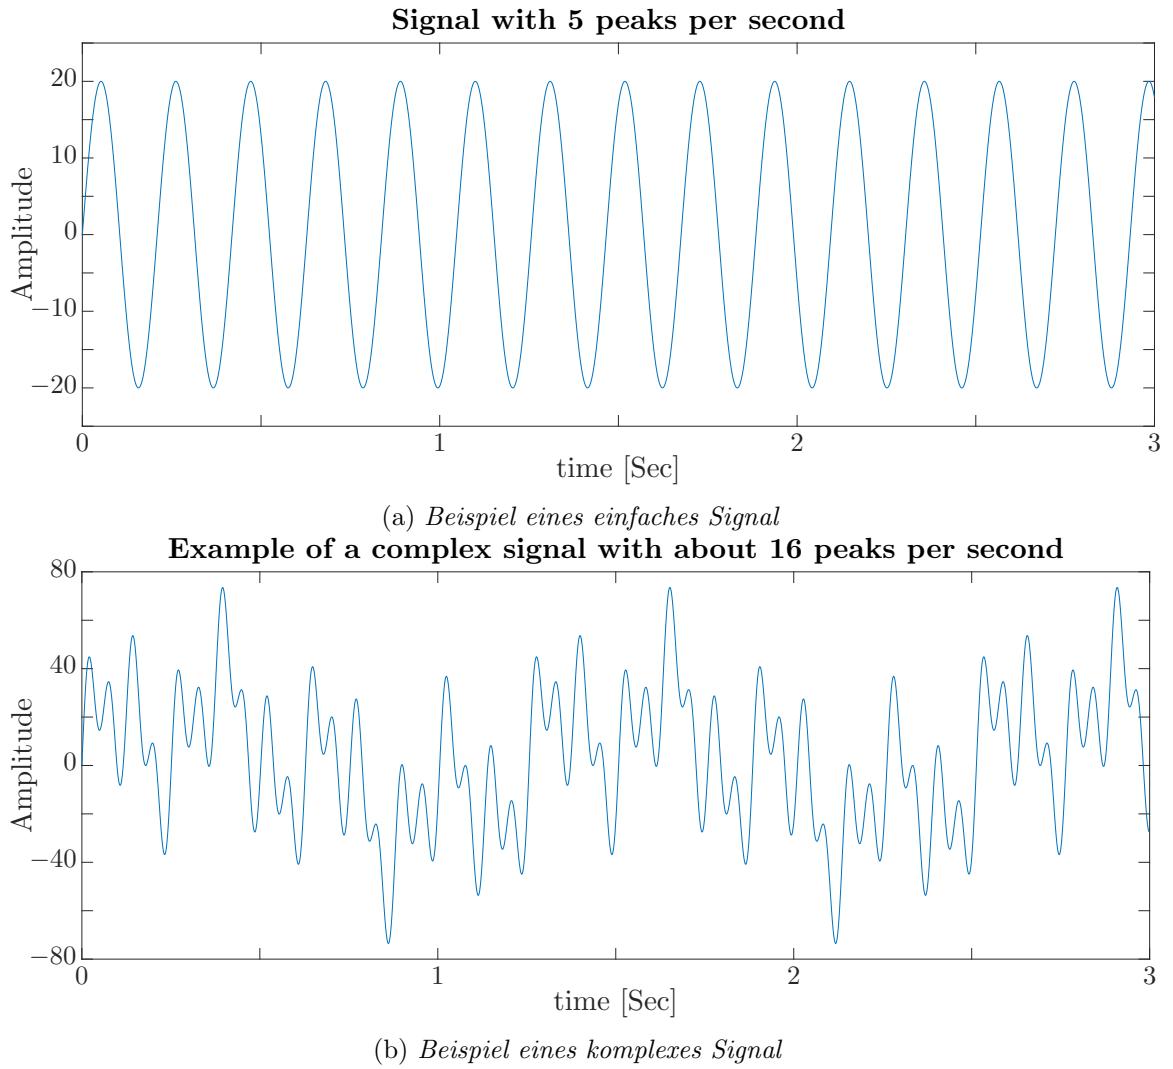


Abbildung 3.6: Skizze eines einfachen ideales Signal sowie eines komplexeres Signal

Beim Einsetzen des gleichen Vorgehens beziehungsweise Model auf das echte Laufsignal (Abbildung 3.3) wird eine Frequenz von ca. 11 Hz beim Laufen zurückgegeben, was eigentlich nicht wahr ist, da der Mensch keine 11 Schritte pro Sekunde zurücklegen kann. Nach weiteren Auswertungen und Forschungen wird der Grund des Fehlers entdeckt. Es liegt an den Unterschied zwischen dem einfachen generierten Sinussignal und dem echten Laufsignal. Das echte Signal hat im Vergleich zum Generierten viele Störungen (Rauschen). Diese lassen sich durch das gedachte Model nicht ausfiltern oder ignorieren, was zu einem falschen Ergebnis führt. Die Abbildung 3.6 stellt ein gutes Beispiel dieser Unterschied dar, in dem die Rauschen die Anzahl der Spitzen erhöhen.

Die Abbildung 3.6 zeigt zwei sinusförmige Signale. Die obere Grafik stellt ein einfaches Signal mit einer Frequenz von ungefähr $f = 5,5 \text{ Hz}$ und die Untere ein komplexes Signal dar. Das Model hat für das untere Signal 19 Spitzen pro Sekunde geliefert, was die Wahrheit nicht entspricht.

Da der Spitzenzähler nicht zuverlässig funktioniert, ist eine bessere Idee notwendig.

3.3.2 Frequenzbasierte Lauferkennung

Das Laufsignal stellt ein wiederholtes Muster (Pattern) durch die Fußbewegungen dar, was auch durch eine Frequenzermittlung erkannt werden kann. Es soll ein Modell gegeben werden, das diese Frequenz ermitteln und auswerten kann. Analog zum Unterabschnitt 3.3.1 wird hier nochmal eine neue Hypothese festgelegt, die durch einem Testsystem überprüft werden soll.

Die Hypothese: Die Frequenz während des Laufens sollte kleiner als 2 Hz sein und beim Fahren über 7 Hz. Wenn eine Frequenz von über 7 Hz ermittelt wird, ist eine Laufaktivität ausgeschlossen, da ein Mensch auf keinen Fall 7 Schritte innerhalb einer Sekunde zurücklegen kann. Die Fahrfrequenz ist durch die Motorumdrehungen entstanden.

Die Transformation vom Zeitbereich zum Frequenzbereich wird durch eine FFT erfolgt. Die App der Unfallerkennung hat eine Abtastrate von $f_s = 100$ Hz und nimmt 100 MesswerteproMesssekunde auf. Bezogen auf die Nyquist-Frequenz (Gleichung 2.2) lässt sich die minimale erkennbare Frequenz (Bandbreite) $f_n = 50$ Hz geben.

Spectrum Analyzer

In der Abbildung 3.7 sind die generierten Sinussignale mit den Frequenzen $f = 23,8$ Hz, $f = 47,8$ Hz und $f = 1,1$ Hz zu sehen, die summiert werden, damit eine Komplexes Signal erstellt wird. Die drei Sinussignale sowie deren Summe sind in der Abbildung 3.10 dargestellt.

Danach wird in diesem Modell ein Block „Spectrum Analyzer“ als Referenz verwendet, was die Grundfrequenzen des komplexen Signals zurückgibt. Der Benutzer kann die Spezifikationen vom „Spectrum Analyzer“ einstellen. Die Ausgabe vom „Spectrum Analyzer“ ist in der Abbildung 3.8 veranschaulicht. In der Oberen Grafik werden die Intensität der Frequenz(en) (auch Spektrum genannt) abgebildet und in der unteren Grafik eine 3D-Darstellung „Frequenz-Zeit-Intensität“ (Spektrogramm), wobei die Farbe die Intensität repräsentiert. Wenn die Abbildung näher betrachtet wird, sind die Grundfrequenzen von $f = 23,8$ Hz, $f = 47,8$ Hz und $f = 1,1$ Hz gut sichtbar.

Testmodel

Nachdem das gedachte Prinzip getestet wurde, ist nun eine Vervollständigung des Modells wichtig. Das vollständige Testmodell ist in der Abbildung 3.9 veranschaulicht. Das Ziel ist die Funktionalität des Prinzips zu überprüfen, bevor dieses mit einem Echtsignal getestet wird.

In dem System sind drei Sinussignale mit verschiedenen Frequenzen generiert, die zusammen summiert werden, um ein komplexes Signal zu erstellen (Abbildung 3.10). Eine vereinfachte Ablaufschema des Models ist in der Abbildung 3.12 gezeigt.

Das Testmodell erstellt zuerst ein komplexes Signal mit bekannten Grundfrequenzen und konvertiert dieses mit dem „Zero-Order-Hold“-Block zu einem diskreten Signal,

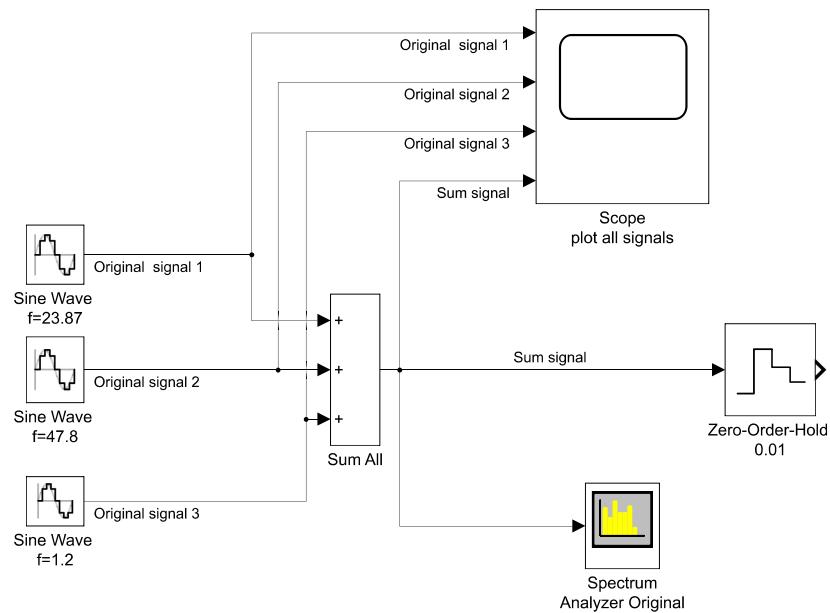


Abbildung 3.7: Testbeispiel - Frequenzbasierte Lauferkennung - Sinussignal

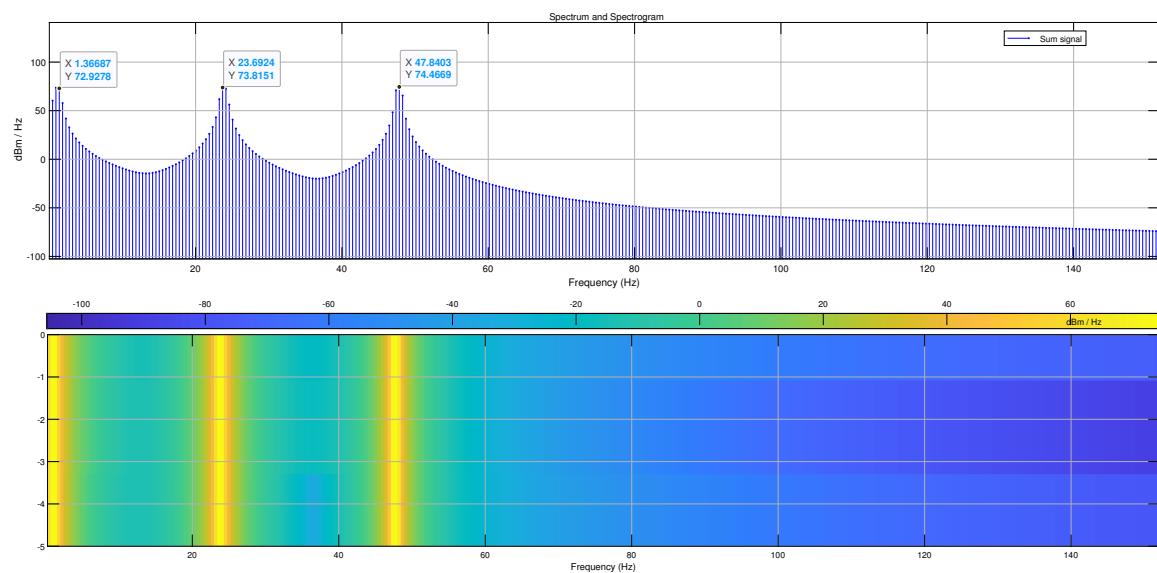


Abbildung 3.8: Testbeispiel - frequenzbasierte Lauferkennung - Ausgabe des Spektrum-Analyzer im Fall eines komplexen Signals

da die FFT nicht auf ein kontinuierliches Signal anwendbar ist. Danach wird das FFT-Fenster durch das „Buffer“-Block eingestellt und dann die FFT an das entsprechende Fenster angewandt. Das Ergebnis der FFT wird weiterbearbeitet, in dem der Betrag gebildet und die Spiegelung entfernt wird. Das Resultat ist eine 2-D-Matrix mit den Intensitäten sowie ihren Indexe auf die Skala 1 bis 512, wobei die Indexe die Frequenzen entsprechen. Das Resultat ist in der Abbildung 3.11 dargestellt. Die Indexe werden extrahiert und in den Skala von 1-100 umgerechnet, in dem diese mit $100/512$ multipliziert. Das Endergebnis des Models ist eine sortierte Liste der tatsächlichen Grundfrequenzen. Die ersten drei Werte haben eine wesentliche große Intensität und sind somit die gesuchten Frequenzen mit minimaler Abweichung.

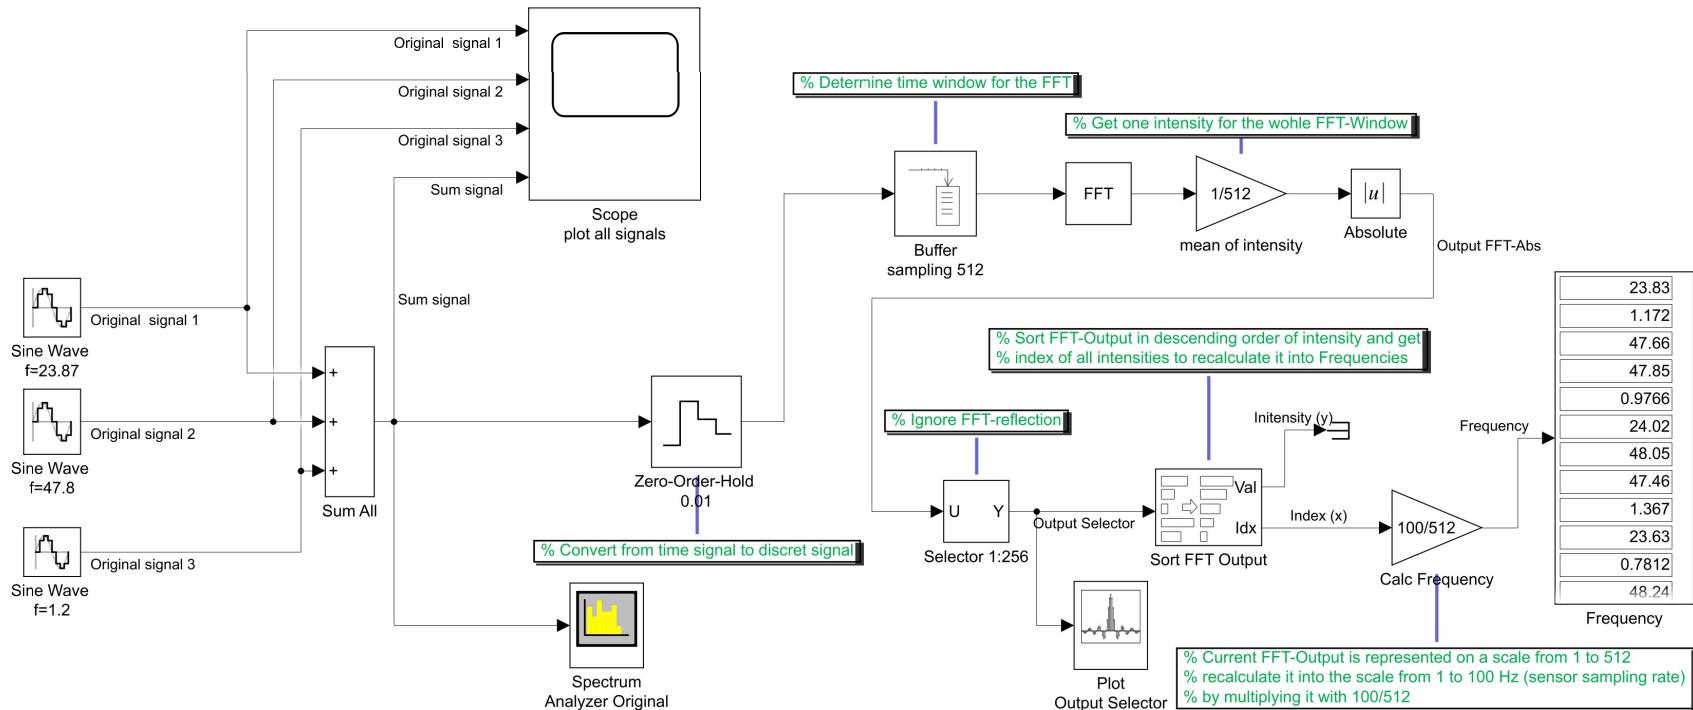


Abbildung 3.9: Testbeispiel - Frequenzbasierte Lauferkennung - FFT

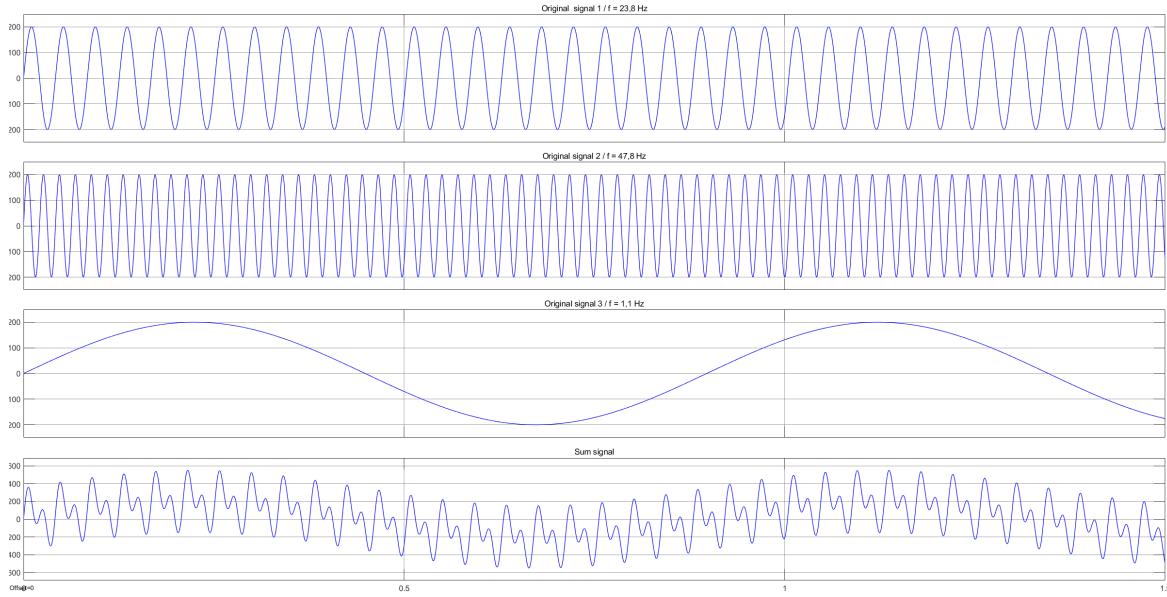


Abbildung 3.10: verschiedene Einzelsignale ($f = 23,8; f = 47,8; f = 1,1$) mit deren Summe f_g

Nachdem die Ergebnisse des Testmodels für Richtigkeit geprüft wurden, wird das System mit einem Echtsignal getestet.

Anwendung auf ein Echtesignal

Zum Anwenden auf ein Echtesignal wird ein Untersystem „MotionDetection“ erstellt, das die Bewegung (Laufen oder fahren) erkennt und zurückgibt. In der Abbildung 3.13 ist einen Teil des genannten Models sichtbar.

Im ersten Teil (1) wird der Betrag aller drei Beschleunigungskomponenten (X,Y,Z) ausgerechnet und dieser für die Lauferkennung verwendet, um diese unabhängig von der Laufrichtung zu bewahren. Der erste Teil kann wie folgt mathematisch beschrieben werden:

$$Acc_g = \sqrt{Acc_X^2 + Acc_Y^2 + Acc_Z^2}$$

In dem zweiten Teil (2) wird eine FFT durchgeführt, um danach die Frequenzen ermitteln zu können. Das Block „Buffer“ stellt das FFT-Fenster (B_L) ein, in dem eine bestimmte Anzahl der Proben (Messungen) gesammelt wird. In diesem Model wird das Fenster auf $B_L = 2,56$ s (d.h. 256 Proben) mit einer Überlappung von 50% eingestellt. Die minimale erkennbare Frequenz lässt sich durch

$$f_{min} = \frac{1}{B_L} = 0,3906 \text{ Hz}$$

berechnen (siehe Unterabschnitt 2.3.1).

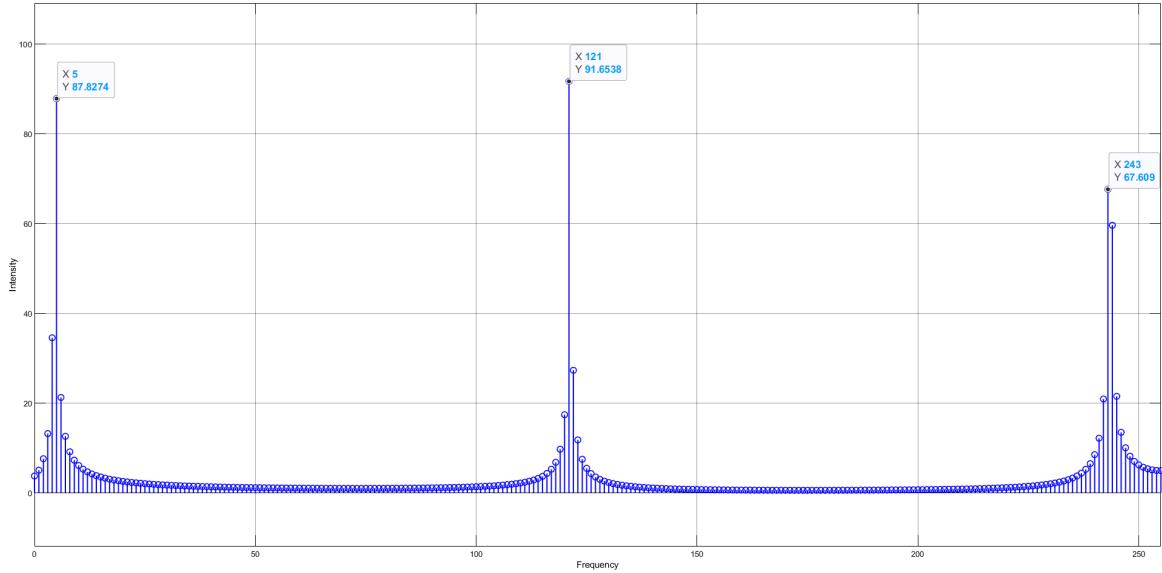


Abbildung 3.11: Das Ergebnis der FFT - Spiegelung entfernt und Beträge

Eine größeres FFT-Fenster B_L hätte eine bessere Frequenzermittlung gesichert und würde allerdings zu größeren Rechenaufwand und längeren Rechenzeiten führen. Die Überlappung dient dazu die Frequenzen am FFT-Fensterrand besser zu berücksichtigen. Danach wird die FFT-Spiegelung mit der Funktion „Select“ vernachlässigt. Der Ausgang dieses Teils ist eine 2-D-Liste auf ein Skala von 1 bis 256, die sortiert werden soll.

Der dritte Teil sortiert die entsprechende Liste nach Intensität. Das Block „Sort FFT Output“ ergibt die Sortierten Intensitäten sowie deren Indexe aus dem ursprünglichen Matrix. Diese Indexe entsprechen die gesuchten Frequenzen auf die Skala (1-256). Mit einer Umrechnung in die Skala (1-100) lassen sich die tatsächliche Frequenzen berechnen. Die „Select“-Blöcke dienen dazu eine Rechenzeit zu verkürzen, in dem nur die Frequenzen mit den zehn größten Intensitäten ausgesucht werden, da nur diese später für die Entscheidung relevant sind.

Die vom dritten Teil ausgegangenen Daten werden zu einer Matlabdatei (Abbildung 3.14) geleitet, wo eine Entscheidung getroffen wird.

Entscheidungskriterien - Matlabskript

Die Abbildung 3.14 zeigt die Matlab-Funktion, die die Entscheidung übers Laufen treffen soll. Die Eingänge der Funktion sind die zehn Frequenzen mit den höchsten zehn Intensitäten sowie die aktuelle Geschwindigkeit. Die durch die Funktion letzte erkannte Aktivität sowie deren Zeitpunkt werden auch in die Funktion weitergeleitet. Nach dem Durchlauf liefert die Matlab-Funktion eine ID-Zahl, die eine Aktivität entspricht. Der Aktivität-ID-Zusammenhang ist in der Tabelle 3.1 abgebildet. Das Skript unterscheidet zwischen vier Klassen. Es wird hauptsächlich zwischen Laufen und Fahren unterschieden, sollte diese Entscheidung nicht möglich, liefert das Skript



Abbildung 3.12: Ablaufschema des Testmodels der Frequenzbasierten Lauferkennung

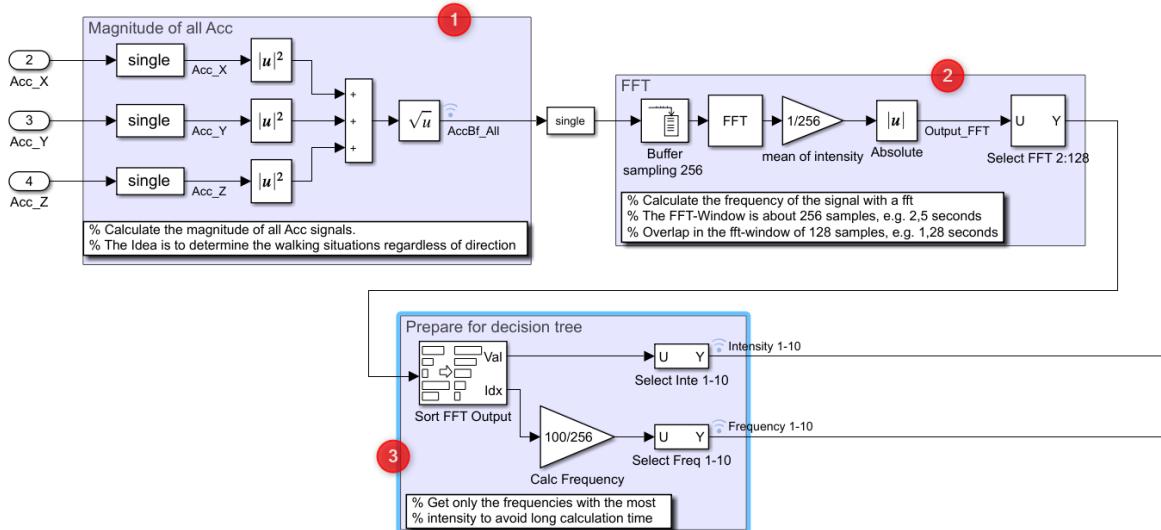


Abbildung 3.13: Das vollständige Echtmodell der Frequenzermittlung im Rahmen der Lauferkennung

Tabelle 3.1: Ausgangsmöglichkeiten der Entscheidungsfunktion

ID	Aktivität
-1	Konflikt/Fehler
0	Keine Bewegung
1	Laufen
2	Fahren

eine Aussage (Unbekannt oder Konflikt) zurück. Die entscheidende Funktion ist Teil des Simulink-System

Die Abbildung 3.15 zeigt das vereinfachte Entscheidungsbaum, wonach die Aktivitätserkennung erfolgt wird.

Die drei Hauptkriterien sind die Frequenz mit ihrer Intensität sowie die gemessene Geschwindigkeit. Wenn die Intensität einen Zulässigen Wert hat, wird die dazugehörige Frequenz berücksichtigt und danach die gelieferte Aussage mit der Geschwindigkeit nachgeprüft. In dem Entscheidungsbaum sind vier Klassen definiert.

- Keine Bewegung
- Laufen
- Fahren
- Konflikt: Wenn die Entscheidungskriterien (Frequenz und Geschwindigkeit) verschiedene Aussagen liefern

Der Entscheidungsbaum fängt bei der Intensität an. Wenn die größte Intensität kleiner als der Schwellwert (100) ist, kann die dazugehörige Frequenz für die Entscheidung

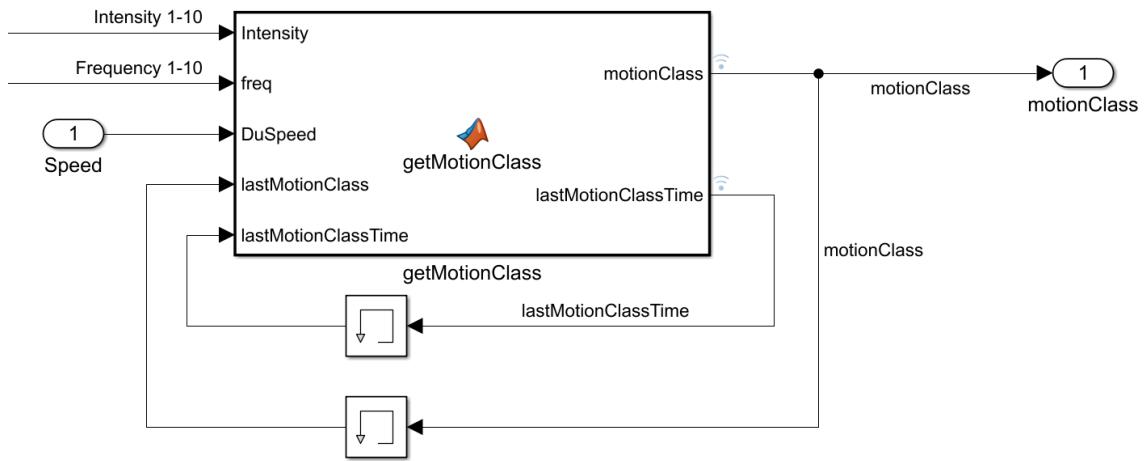


Abbildung 3.14: Ein- und Ausgänge des Entscheidungsskripts

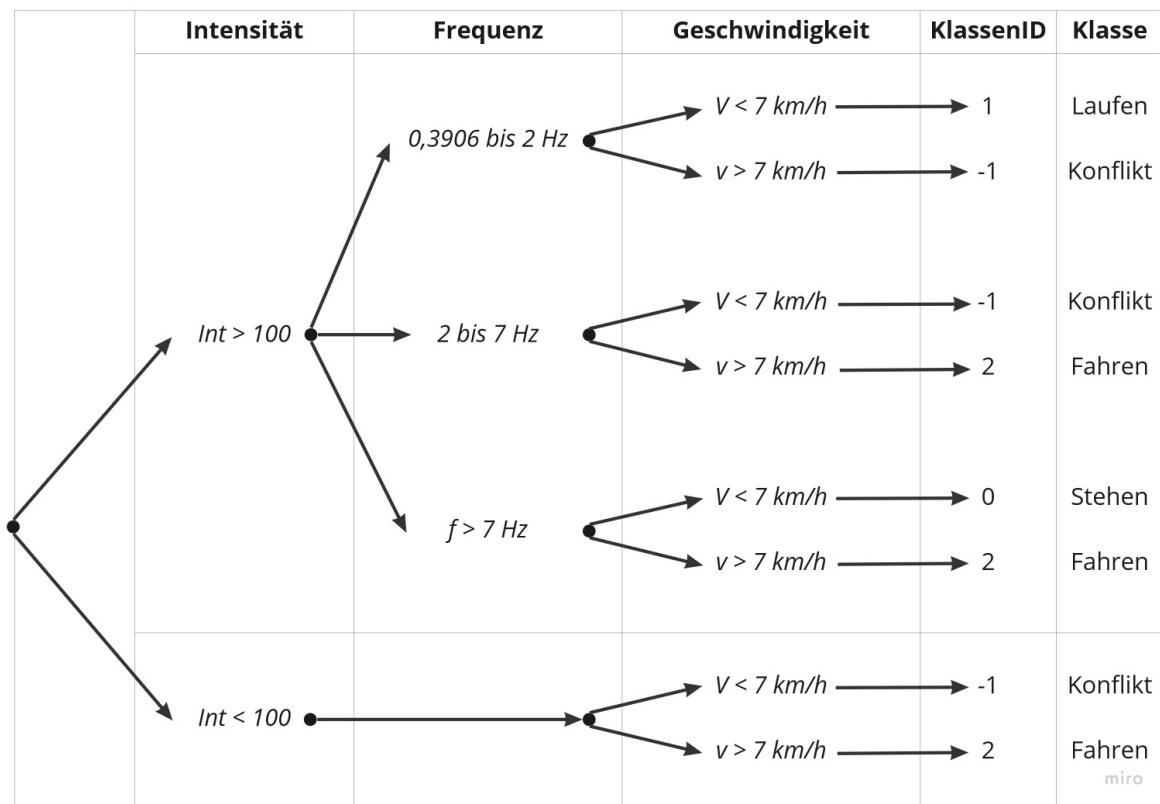


Abbildung 3.15: Entscheidungsbaum der Aktivitätserkennung

nicht vertrauend sein und werden bis zu vier nachfolgenden Intensitäten untersucht. Sollte immer noch keine zulässige Intensität ergeben, wird sofort nach Geschwindigkeit geschaut und diese für die Entscheidung verwendet. Z.B. Bei einer Geschwindigkeit von 30 km/h ist von einer Fahr auszugehen und bei 3 km/h vom Laufen.

Kommt eine zulässige Intensität vor, wird die dazugehörige Frequenz berücksichtigt. Eine Frequenz unter 2 Hz bedeutet „Laufen“ und über 7 Hz entspricht „Fahren“. Es wird danach mit der Geschwindigkeit nachgeprüft. Eine Geschwindigkeit von über 7 km/h bedeutet auf jeden Fall „Fahren“ und darunter „Laufen“. Wenn die Frequenz- und Geschwindigkeitsüberprüfung verschiedene Aussagen zurückgeben, ist von einem Konfliktsituation auszugehen. In diesem Fall werden bis zu vier größten nachfolgenden Frequenzen überprüft.

Testbeispiel

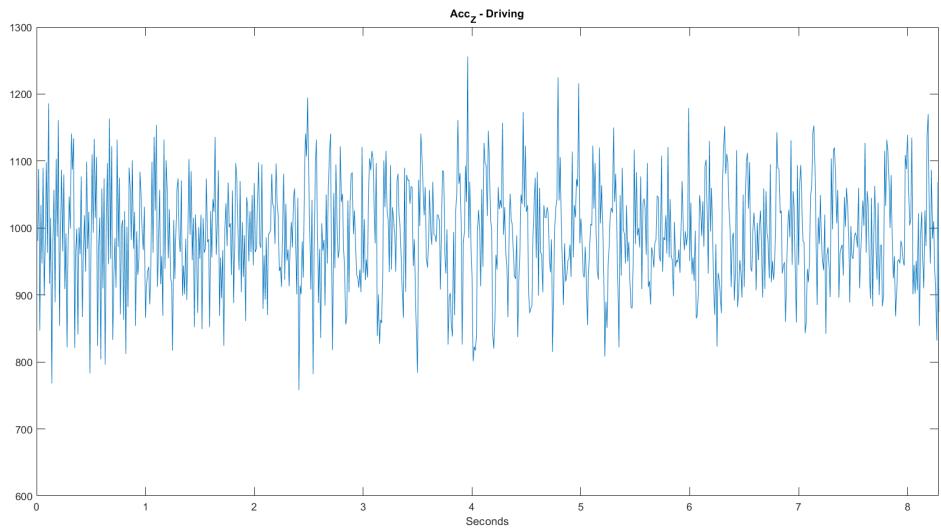
Die Signale in der Abbildung 3.16 sind aus einem Echtesignal ausgeschnitten, in dem der Fahrer nach einer Fahrt gelaufen ist. Das Fahren ist in der Abbildung 3.16a sowie das Laufen in der Abbildung 3.16b abgebildet.

Nachdem Aktivitätserkennung mit diesem Signal getestet wurde, hat das Model die richtigen Frequenzen erkannt. Für das erste Teilsignal aus der Abbildung 3.16a hat eine Frequenz von durchschnittlich 20 Hz geliefert. Das Teilsignal aus der Abbildung 3.16b hat eine Frequenz von etwa 1,8 Hz. Die Frequenzermittlung der Lauferkennung war sehr nah zur Realität. Nachdem die Frequenzen ermittelt wurden, sind diese ins Entscheidungsskript weiterzuleiten. Das Skript entscheidet dann mit einer Geschwindigkeitsprüfung, welche Aktivität (Fahren oder Laufen) vorgekommen ist.

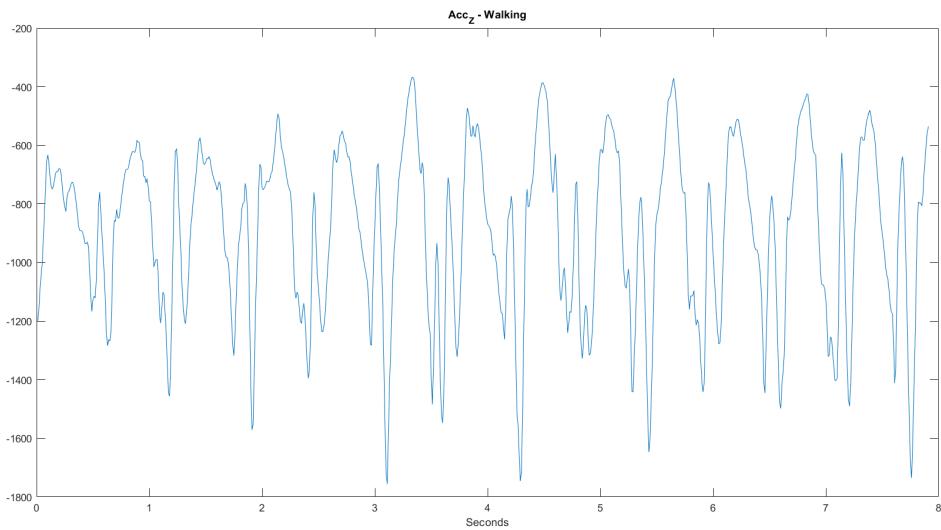
Sinnvolle Werte auswählen

Nachdem das Testmodel gute Ergebnisse geliefert hatte, sollen die ausgewählte Schwellwerte diskutiert werden.

- **Intensität:** Der Entscheidungsbaum sucht nach einer Intensität von über 100, damit die dazugehörige Frequenz vertrauend zur Entscheidung verwendet werden kann. Nach mehreren Testungen wurde eine Intensität von 100 ausgewählt. Ein niedriger Intensitätswert führt zu einer möglichen falschen Entscheidung, da die Rauschen beziehungsweise die kleinen Frequenzen aus dem Frequenzbereich fälschlicherweise in das Entscheidungsskript eingeleitet werden.
- **Frequenzbereich:** das entspricht den Frequenzbereichen vom Laufen und vom Fahren.
Der Lauffrequenzbereich beträgt in der Regel kleiner als 2 Hz. Das Motorrad schafft wesentlich mehr als 7 Hz (mehr als 420 Umdrehungen pro Minuten).
- **Geschwindigkeit:** In dem Skript ist ein Wert von 7 km/h als Schwellwert zwischen Fahren und Laufen ausgewählt. Der Wert ist in der Straßenverkehrsordnung als Schrittgeschwindigkeit anerkannt [Bussgeldkataloge, 2022]. Erfah-



(a) Beispieldesignal - Laufen



(b) Beispieldesignal - Fahren

Abbildung 3.16: Abgeschnittene Teile eines Beispieldesignals

rungsmäßig läuft der Mensch allerdings in einer Geschwindigkeit zwischen 5 km/h und 10 km/h.

3.4 Auf- und Absteigen

In der Umgangsphase zwischen Fahren und Laufen steigt die Person ab oder auf. Beim Auf- und Absteigen entsteht eine starke Winkeländerung in der Beinposition, da der Fahrer sein Bein über das Motorrad hebt und manchmal nach hinten streckt. Wenn das Smartphone in der Hosentasche ist, bekommt es die Winkeländerung ganz klar mit. Eine theoretische Betrachtung dieser Bewegung schlägt einen Fehlalarmauslösung vor, da die Winkeländerung zu der Sitzposition über 45° liegt, was in der Regel durch das Model „TipOver“ als Umkippen erkannt wird. Aus diesem Grund wird dieses Szenario für die Richtigkeit getestet.

3.5 Anhalten

In diesem Abschnitt wird ein Szenario aus der Tabelle (Abbildung 3.2) analysiert, in dem der Fahrer während einer Fahrt an eine Ampel für kurze Zeit anhält und sein Fuß runter setzt. In diesem Fall ist das Smartphone in der Hosentasche des bewegenden Beins platziert. Die Annahme, dass in so einem Fall im Pocket-Mode ein falscher Alarm ausgelöst werden könnte. Der Grund ist die Winkeländerung von ca. 90° zwischen den zwei Beinpositionen, was das Model „TipOver“ aktiviert und zu einer Alarmauslösung führt. Die erste Position ist das Bein während einer Fahrt mit der horizontalen Beinstellung. Wenn der Fuß am Boden ist, steht das Bein in einer vertikalen Postion.

In der Abbildung 3.17 ist ein Beispielsignal eines Smartphones abgebildet. Die Grafik stellt das Signal in zwei Smartphone-Positionen (Vertikal und Horizontal) dar und zeigt einen Winkelunterschied von ca. 90°. Diese Winkeländerung soll das „TipOver“-Model aktivieren und schlägt eine Unfallerkennung vor. Dieses Szenario wird ebenfalls für die Richtigkeit getestet und analysiert.

3.6 Verifikation des Algorithmus

Die Verifizierung dient dazu, die Annahmen und Hypothesen aus den letzten Abschnitten zu prüfen, sowie die implementierte Aktivitätserkennung zu testen.

Im Rahmen dieser Verifizierung wird eine Versuchsplanung durchgeführt. Demnächst wird die Versuchsplanung sowie das Versuchsvorgehen erläutert.

3.6.1 Versuchsplanung

In diesem Abschnitt wird auf die zu testenden Szenarien sowie deren Durchführung eingegangen.

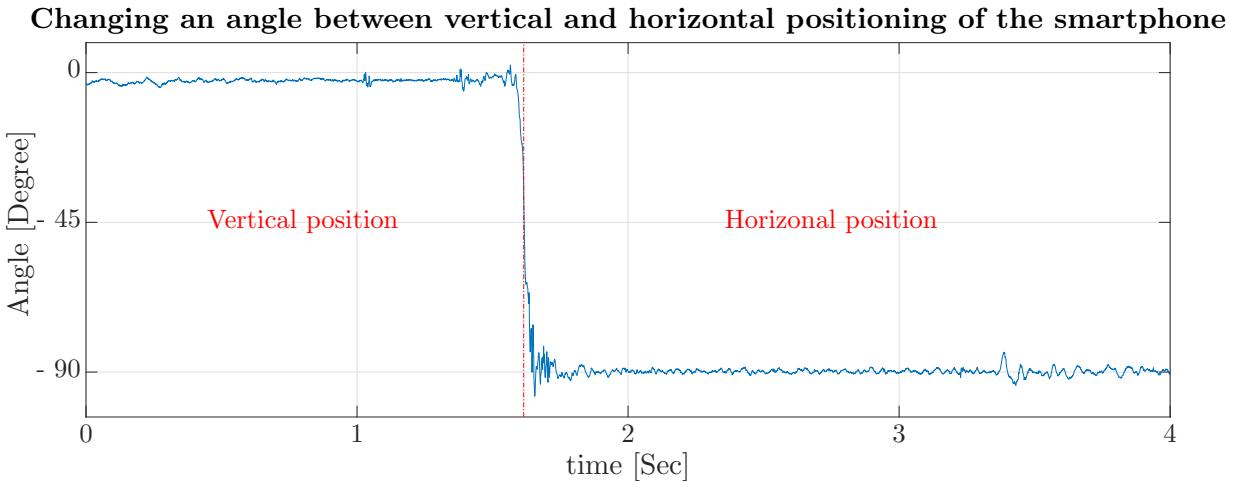


Abbildung 3.17: Winkeländerung im Signal zwischen vertikaler sowie horizontaler Smartphone-Positionierung

Die Abbildung 3.2 zeigt eine Liste der Use- und Edgecases, in der einige Szenarien getestet werden sollen. Es wurden diesbezüglich fünf verschiedene Szenarien geplant. Die Tabelle (Abbildung 3.18) fasst diese zusammen und zeigt die verwendeten Smartphones sowie ihren Ablageorten (Hosentasche, Brusttasche... usw.) während des Testens. Das erste Szenario soll die implementierte Lauferkennung testen sowie das Verhalten beim Auf- und Absteigen aufzeichnen. Dadurch soll das Signalunterschied zwischen der Fahrt und des Laufens erkennbar sein. Zusätzlich wird die Winkeländerung zwischen der zwei Fahrerpositionen (stehend/sitzend) während einer Fahrt analysiert und getestet. Das zweite Szenario testet die tatsächliche Winkeländerung zur ursprünglichen Position des Smartphones nach der Kalibrierung sowie die Reaktion des Algorithmus beim Anhalten, da der Fall während einer Fahrt sehr oft vorkommen könnte.

Die dritte sowie vierte Szenario sollen das Verhalten des Smartphones testen, wenn es sich im Tankrucksack ohne Befestigung befindet. Das letzte Szenario testet die Reaktion des Algorithmus, wenn der Fahrer während einer Fahrt runter fällt und ob der Algorithmus diesen Fall zuverlässig erkennt. Um die zufällige Fehler bei der Signalaufnahme zu vermeiden werden bei der Testung immer mehr als ein Smartphone verwendet. Es werden ebenfalls bei manchen Szenarien mehrere Smartphones an mehreren Ablageorten hingebracht, um möglichst viele Daten gleichzeitig zu sammeln und der Verhaltensunterschied des Algorithmus an unterschiedlichen Orten zu forschen. Die Auswertung dieser Daten wird je nach der verfügbaren Zeit erfolgt.

Der Versuchsablauf wird vor dem Testen vorbereitet und möglichst detailliert geplant, damit während des Testens kein Zeitverlust entsteht. Demnächst werden die allgemeine Schritte des Versuchsablaufs aufgelistet.

- 1 Befestigung und Einstellung der Kameras am Lenker und an der Brust, um die Wahrheit (Ground Truth) für die spätere Auswertung aufzunehmen
- 2 Befestigung der Smartphones (inklusive das Referenzhandy am Lenker) in der

3 Unfallerkennung im Pocket-Mode

Sz-Nr.	Anz. Durchläufe	Beschreibung	Smartphones				
			iPhone SE	Samsung A5	Samsung S10	Pixel 3	Huawei P30
1	2	Fahren, Auf der Fußraste stehen, Auf- und Absteigen, Laufen	Lenker	Hosentasche	Tankrucksack	Brusttasche	Rucksack
2	1	Anhalten	Lenker	X	X	Hosentasche	Hosentasche
3	1	Handy im Tankrucksack rutschen lassen (eine Ebene)	Lenker	X	X	Tankrucksack	Tankrucksack
4	1	Handy im Tankrucksack rutscht (Mehrere Ebenen)	Lenker	X	X	Tankrucksack	Tankrucksack
5	2	Crash simulieren; Rucksack während einer Fahrt fallen lassen	Lenker	X	X	Rucksack	Rucksack

Abbildung 3.18: Die Zusammenfassung der getesteten Szenarien

geplanten Stellen, Einschaltung und Prüfung der Signalaufnahme

- 3 Eine Kalibrierungsfahrt
- 4 Prüfung der Smartphoneskalibrierung
- 5 Start der Videoaufnahme und Dokumentation von Datum sowie Uhrzeit
- 6 Durchführung des Testversuchs (Variiert je nach dem Versuchsszenario)
- 7 Fahrtende und absteigen
- 8 Datenexport und -Übertragung
- 9 Datenexistenz im Zielordner prüfen
- 10 Löschung der Daten im Smartphone
- 11 Vorbereitung des nächsten Versuchs beziehungsweise Durchlaufs

Das erste Szenario ist das Wichtigste für diese Arbeit, weil dadurch die implementierte Lauferkennung sowie den Unterschied der Aktivitätserkennung zwischen den verschiedenen Bewegungsarten (z.B. Laufen, Fahren) getestet und verifiziert werden. Die einzelne Testschritte dieses Szenario werden hiermit erläutert:

- Szenario 1: Fahrt mit verschiedener Fahrerpositionierung und Laufen sowie der Übergang dazwischen (Auf- und Absteigen)
 - 1 Start der Videoaufnahme und Dokumentation von Datum sowie Uhrzeit
 - 2 Normale Fahrt für ca. eine Minute
 - 3 Fahrt in stehender Fahrerposition für ca. 10 – 20 Sekunden

- 4 Normale Fahrt für ca. eine Minute
- 5 Anhalten und Absteigen
- 6 Laufen für 30 – 40 Sekunden
- 7 Wieder Aufsteigen und eine normale Fahrt für ca. eine Minute
- 8 Fahrt in stehender Fahrerposition für ca. 10 Sekunden
- 9 Normale Fahrt für ca. eine Minute
- 10 Fahrtende und Fahrerabstieg

Gleichzeitig werden die durch das integrierte Google-Tool erkannten Aktivitäten aufgenommen, damit diese mit der Ausgabe des implementierten Model „Aktivitätserkennung“ verglichen werden. Das Ziel ist zu prüfen, ob es zuverlässiger wäre, das integrierte Tool zu verwenden.

3.6.2 Referenz-Aktivitätsdaten (Ground truth)

Die Lauferkennung beziehungsweise Aktivitätserkennung ergibt die Aussage (Fahren oder Laufen) und soll demnächst getestet werden. Für die Testung muss der tatsächliche Verlauf einer Fahrt bekannt werden. Zu diesem Zweck werden die Tests mit Videoaufnahmen nach der Durchführung optisch manuell mithilfe eines intern entwickelten LabVIEW-Tool ausgewertet. Diese Versuche sind mit Videos aufgenommen, die allerdings nur einen kleinen Teil der aufgezeichneten Signale abdecken. Damit die Videos dem richtigen Signalteil zugeordnet werden können, ist eine Synchronisierung zwischen dem Signal und dem dazugehörigen Video erforderlich.

Der Benutzer kann mit dem internen Tool die Video-Signal-Synchronisierung unkompliziert erfolgen. Danach können bestimmte Labels (z.B. Fahren oder Stehen) für die entsprechenden Zeitfenster schnell und einfach eingegeben werden. Am Ende wird eine Tabelle exportiert, welche die gleiche originalen Daten sowie eine neue zusätzliche Spalte mit den Labels der Aktivitäten beinhaltet. Diese Tabelle kann mit den Ergebnissen der Lauferkennung verglichen werden.

Die erwähnte Labels muss der Benutzer vorher definieren und in das Tool importieren. In der Abbildung 3.20 ist die Tabelle der definierten Labels sichtbar. Die Tabelle hat sieben verschiedene Klassen, die sich im Tool mit den F-Tasten einfach eingeben lassen. „Undefined“ entspricht unbekannter Eingabe, wenn das Motorrad nicht im Video sichtbar ist. „Driving“ repräsentiert der Fahrt und „Walking“ des Laufens. In der Abbildung 3.19 ist ein verkürztes Beispiel der exportierten Tabelle, in der die neue Spalte „GroundTruthID“ sichtbar ist. In der Tabelle sind mehrere ausgeschnittene Phasen enthalten, die auch durch die GroundTruth-Daten unterschieden werden.

timeStamp	acc	gyr	speed	angle	groundTruthID	groundTruth
167298	-987	953	29.67358	1.982636	2	Driving
167299	-855	-3893	29.67358	1.8454454	2	Driving
167300	-831	-6851	29.67358	1.6600937	2	Driving
167302	-710	1347	29.67358	1.3874936	0	No Movement
167895	-780	-5993	41.201656	-4.920791	0	No Movement
167896	-783	-7708	42.258587	-4.896966	0	No Movement
167897	-832	-5459	42.258587	-4.8466144	1	Walking
167898	-833	-1916	42.258587	-4.7872252	1	Walking
167899	-874	516	42.258587	-4.7530065	1	Walking
170005	143	-1907	30.31143	2.5846107	0	No Movement
170006	152	-1837	30.31143	2.5952225	0	No Movement
170007	130	-1697	30.31143	2.611972	0	No Movement
170008	138	-988	30.31143	2.6297727	2	Driving
170009	148	78	30.31143	2.6537619	2	Driving
170010	141	78	30.31143	2.7010856	2	Driving
170012	151	1006	3.5	2.760584	0	No Movement
170013	150	796	2.1	2.7934167	0	No Movement
170014	148	796	0	2.8240378	0	No Movement
170020	158	2694	30.31143	3.1481538	-1	Undefined
170021	153	1986	30.31143	3.2035604	-1	Undefined
170022	149	1487	30.31143	3.2570984	-1	Undefined

Abbildung 3.19: Beispiel der exportierten Tabelle mit der neuen Spalte

ID	Class	F-Key
-1	Undefined	F4
0	No Movement	F5
1	Walking	F1
2	Driving	F2

Abbildung 3.20: Die definierte Labels von Groundtruth

4 Ergebnisse

In diesem Kapitel wird die implementierte Lauferkennung ausgewertet und werden ebenfalls die Ergebnisse der Testversuchen vorgestellt und diskutiert.

Die Auswertung der Versuche beziehungsweise der Testergebnisse wird aus zeitlichen Gründen qualitativ sein und nicht quantitativ.

4.1 Verifizierungsversuche

Die bereits im Unterabschnitt 3.6.1 aufgelistete Versuchsszenarien wurden alle mindestens einmal getestet. Einige Testszenarien sind mit zwei Testdurchläufe durchgeführt. Nach der Durchführung der Verifizierungsversuche werden die Ergebnisse analysiert und diskutiert.

Die Lauferkennung ist ein großer Teil dieser Arbeit und wird demnächst mit den tatsächlichen Daten (Ground Truth) sowie die von Google integrierte Aktivitätserkennung verglichen.

4.2 Lauferkennung

In der Abbildung 4.1 werden die verschiedenen Methoden der Aktivitätserkennung sowie die Geschwindigkeit in der obersten Grafik über die Zeit dargestellt.

Die zweite Grafik zeigt die tatsächliche Aktivitätsdaten (Ground Truth), die in vier Klassen (Abbildung 4.2) unterteilt sind. Die Aktivitätsbereiche sind auch mit vertikalen roten Linien optisch unterteilt, die auch in anderer Grafiken sichtbar sind, damit diese einfach und schnell zugeordnet werden können. Bei der Sekunde 460 s sowie 500 s ist die Versuchsperson vom Motorrad ab- oder aufgestiegen, deswegen werden diese zwei Stellen mit „No Motion“ klassifiziert. Ab der Sekunde 556 s gibt es keine Videoaufnahme mehr und wurde als „Undefined“ eingetragen.

In der dritten Grafik ist die Ausgabe der im Rahmen dieser Arbeit implementierten Lauferkennung beziehungsweise Aktivitätserkennung abgebildet. Es ist zu bemerken, dass die Lauferkennung ein sehr große Übereinstimmung mit den Ground Truth hat. Laufen sowie Fahren werden dadurch gut erkannt. Das Auf- und Absteigen bei den Sekunden 465 s und 508 s werden die „No Motion“-Klasse vom Lauferkennung-Model vergeben.

Die letzte Grafik stellt die Ausgabe der im Smartphone integrierten Aktivitätserkennung dar, die für diese Auswertung in die gleiche Klassifizierung aus der Abbildung 4.2 umgerechnet wird.

4 Ergebnisse

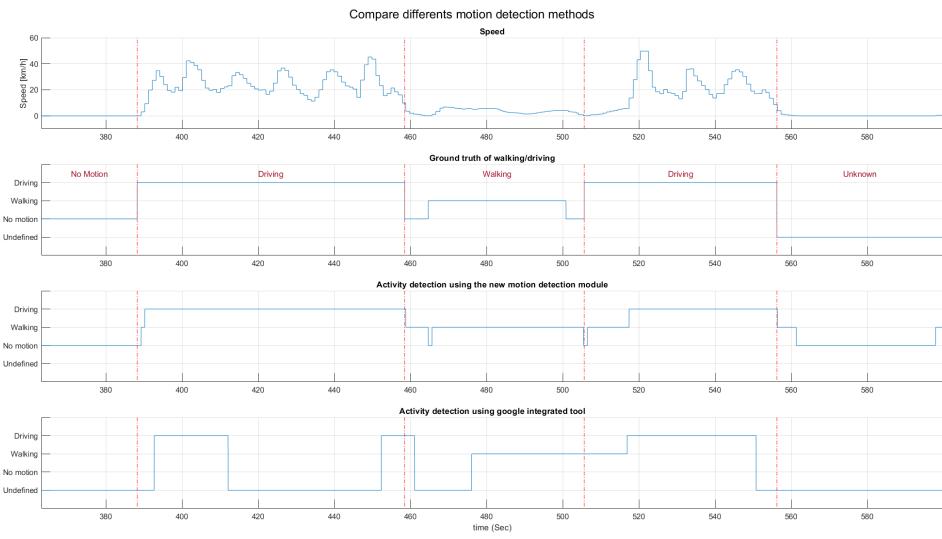


Abbildung 4.1: *Ergebnis des Lauferkennungsmodells*

KlassenID	Beschreibung
Undefined	Unbekannt oder keine Videoaufnahme
No Motion	Keine klassifizierbare Bewegung
Walking	Laufen
Driving	Fahren

Abbildung 4.2: *Beschreibung der Klassen in der Grafik Abbildung 4.1*

Aus der Abbildung 4.1 ist letztendlich zu bemerken, dass die Aktivitätserkennung durch das implementierte Model gute Ergebnisse liefert, die mit der Wahrheit sehr gut übereinstimmt. Im Vergleich zu der Google-Aktivitätserkennung (unterste Grafik) hat das Model eine wesentlich bessere Aussage getroffen. Die implementierte Aktivitätserkennung verbraucht keine große Rechenzeit (ca. 2 bis 3 Sekunden) und erfolgt in Echtzeit mit einer kleinen Verzögerung (ca. 2,5 s), da die FFT erst durchführbar, wenn 256 s vorhanden sind.

4.3 Verschiedene Fahrerpositionierung

Die Abbildung 4.1 dient zur Auswertung des ersten Testszenarios aus der Abbildung 3.18, in dem die Person während einer Fahrt auf der Fußraste des Motorrads für paar Sekunden steht und wieder sitzt. Das Ziel dieses Tests ist zu prüfen, ob die Änderung der Fahrerposition während einer Fahrt zur falschen Alarmauslösung führt.

Diese Darstellung zeigt die Geschwindigkeit, die Fahreraktivität (Fahren/Laufen), die Fahrerposition sowie die Winkeländerung über die Zeit.

Die Geschwindigkeit (blau) sowie die während der Fahrt Alarmauslösungen (lila) sind in der ersten Grafik abgebildet. Die zweite Grafik stellt die tatsächliche Fahrerposition (Ground Truth) über die Zeit dar, die in drei Klassen (Sitzen, Stehen oder unbekannt) unterteilt sind. Die Fahrerpositionsbereiche sind ebenfalls durch vertikale rote Linien optisch geteilt, die auch in anderer Grafiken sichtbar sind, damit diese einfach und schnell zugeordnet werden können. In der Zeitbereich zwischen 465 s und 505 s ist die Versuchsperson gelaufen, deswegen lautet die Klassifizierung „Unbekannt“, da die gedachte Klassen so ein Fall nicht abdecken.

In der dritten Grafik sind die tatsächlichen Aktivitätsdaten (Ground Truth), die in vier Klassen (Abbildung 4.2) unterteilt sind. Die Aktivitätsbereiche sind auch mit vertikalen roten Linien optisch unterteilt. Beim Ansehen der zweiten und dritten Grafik wird einen guten Überblick über die Fahrt verschafft. Zwischen der Sekunden 388 s und 459 s fand eine Fahrt statt, während dieser ist der Fahrer zwischen der Sekunden 410 s und 433 s gestanden.

Die Kurve aus der letzten Grafik zeigt die Winkeländerung des Smartphones im Vergleich zur ursprünglichen Position nach der Kalibrierung. Aus der Darstellung ist die Winkeländerung während der ersten Fahrt, als die Fahrerposition sich verändert hat, sehr gut sichtbar. Das Laufmuster ist in diesem Signal zwischen 465 s und 500 s ebenfalls gut erkennbar.

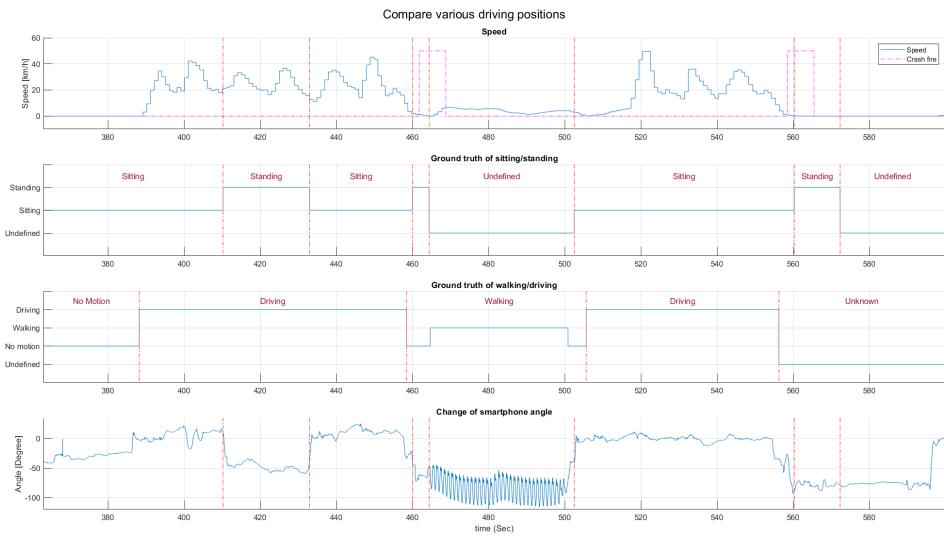


Abbildung 4.3: Zeitlicher Verlauf der Geschwindigkeit, Ground Truth der Fahreraktivität und -Position sowie der Winkeländerung

Es ist wichtig zu bemerken, dass die Änderung der Fahrerposition während einer Fahrt keine Fehlalarme ausgelöst hat, da die Winkeländerung in so einem Fall nicht genug groß ist, um das „TipOver“-Model zu aktivieren. Beim Absteigen (ca. 460 s und 560 s) gibt es allerdings eine Alarmauslösung, da es an der Stelle sehr große Winkeländerung gibt, da der Fahrer seine Bein nach außen und hinten gestreckt hat.

4.4 Anhalten

Dieser Abschnitt diskutiert das Ergebnis des zweiten Testszenarios aus der Abbildung 3.18, in dem die Versuchsperson während einer Fahrt kurz anhält und sein Fuß runter setzt.

Die Grafik Abbildung 4.4 zeigt die Geschwindigkeit sowie die Winkeländerung zum ursprünglichen Position nach der Kalibrierung über die Zeit. Während des Tests war gesehen, dass der Fahrer dreimal anhält und sein Fuß runter setzt, was in der Geschwindigkeitskurve sichtbar ist (262 s, 315 s und 350 s). Es wurde während des Tests keine Fehlalarmauslösung entgegen den Erwartungen gegeben. Nach tieferen Analyse ist der Grund bekannt worden.

Die Winkeländerung beträgt nicht 90° sondern nur ca. 20° - 30° (Abbildung 4.5). Die Person hat sein Bein beim Sitzen nicht genau horizontal sondern leicht nach Unten gebogen. Wenn der Fahrer sein Fuß runter setzt, ist diese ebenfalls nicht genau vertikal sondern leicht gebogen mit einem Winkel von ca. 10° - 20° zur vertikalen Strich. D.h. die Winkeländerung ist nicht über 45° und sollte auch zu keinen Alarmauslösungen führen.

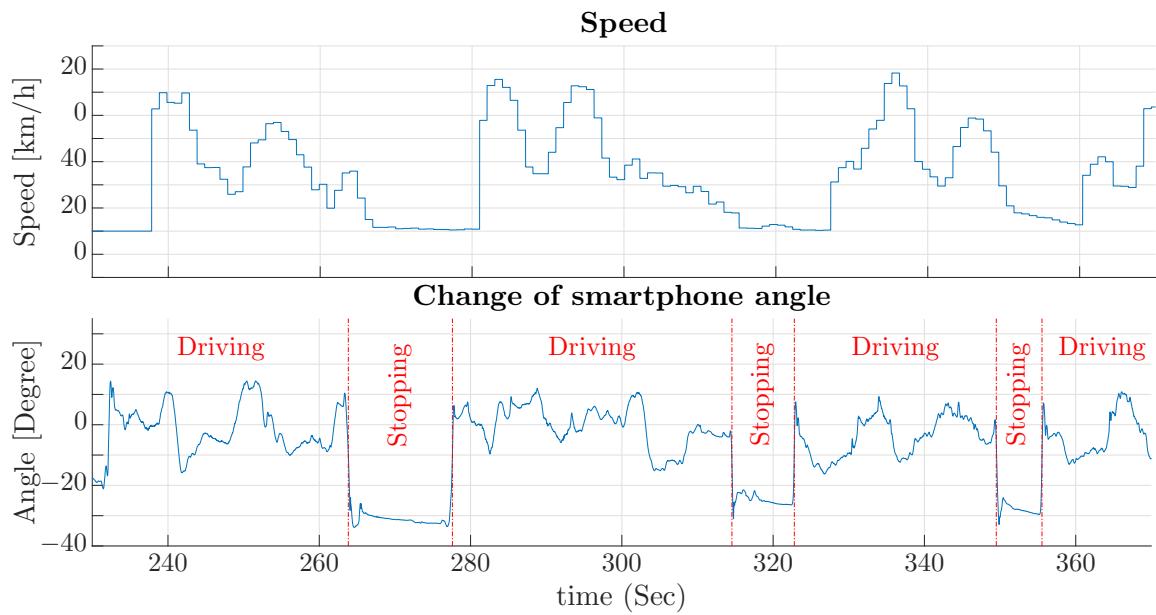


Abbildung 4.4: Winkeländerung des Smartphones durch das Anhalten



(a) Beinposition während einer Fahrt

(b) Beinposition Beim Stehen

Abbildung 4.5: Beinpositionen während einer Fahrt und beim Anhalten

5 Ausblick

Da die Motorradfahrer eine besonders gefährdete Gruppe an Verkehrsteilnehmern darstellt, soll eine automatisierte Unfallerkennung mithilfe des Smartphones von großen Bedeutung sein, welche Unfälle erkennt, klassifiziert und mithilfe der Bosch geschulten Agenten die lokale Rettungsdienste warnt. Diese Arbeit war ein Teil der Entwicklung des Unfallerkennungsalgorithmus im Taschenmodus, damit die Unfallerkennung auch mit dem Smartphone in der Jacken- oder Hosentasche funktionsfähig bleibt.

Aus zeitlichen Grunde und da das Projekt „Bosch Help Connect“ bis Ende 2022 eingestellt wurde, war eine umfangreiche Entwicklung des Taschenmodus leider nicht mehr möglich. Im Folgenden wird ein Ausblick auf mögliche Ideen zur Weiterentwicklung der bisherige Version des Algorithmus gegeben, welche an den Inhalt dieser Arbeit angrenzen sowie die Unfallerkennung zur weiteren Nutzung bringen würde.

Im aktuellen Unfallerkennungsalgorithmus ist gesehen, dass der Fahrer die Unfallerkennung manuell aktivieren und deaktivieren muss. Eine im Hintergrund kontinuierliche Aktivitätsüberwachung könnte implementiert werden und bei einer Motorradfahrterkennung wird die Unfallerkennung automatisch aktiviert. Das spart dem Benutzer Zeit und Aufwand, vor Allem wenn das Smartphone sich im Rucksack befindet.

Die Aktivität- beziehungsweise Lauferkennung soll weiterentwickelt und zuverlässiger implementiert werden, in dem andere Smartphone-Daten (z.B. Bildschirmaktivität oder App-Nutzung) mit analysiert werden. Eine Funktion zur Erkennung der Smartphone-Hebung (mobile lifting detection) sollte die Smartphonenuutzung ebenfalls erkennen. Die Unfallerkennung sollte in diesem Fall temporär deaktiviert werden, damit die falsche Alarmauslösungen während dieser Benutzung verhindert werden.

Die Verifizierung der im Rahmen dieser Arbeit implementierten Lauferkennung fand nur qualitativ statt, diese soll demnächst quantitativ durchgeführt werden. Nach einer ausreichende Testung sollen die Schwellwerte wie Laufgeschwindigkeit oder Fahrfrequenz gegebenenfalls angepasst werden.

Der Algorithmus zur Unfallerkennung soll auch für anderen Transportmittel wie z.B. Mofa, E-Scooter, usw. angepasst werden, damit dieser einheitlich bei mehreren Transportmittel verwendbar bleibt. Eine Sturzerkennung der Person während des Laufen oder der anderen alltäglichen Aktivitäten könnte sehr hilfreich sein.

Die Reaktionstestung des Algorithmus soll ebenfalls für alle mögliche Szenarien ausreichend getestet werden, damit eine signifikante Aussage getroffen werden kann. Bei einer Abweichung von der Erwartung ist eine Gegenmaßnahme zu testen und gegebenenfalls diese Maßnahme anzupassen.

Die Ermittlung der Unfallschwere soll zukünftig mit besserer Aussage entwickelt werden. Bei einem schweren erkannten Unfall kann die Zwischenphase mit dem Bosch Agent übersprungen werden, in dem die Rettungsdienste automatisch kontaktiert und

dadurch Zeit gespart werden.

Literaturverzeichnis

[AWS 2022] AWS: *What is Mobile Application Development?* <https://aws.amazon.com/mobile/mobile-application-development/>. Version: Oktober 2022. – Aufgerufen am 22.11.2022

[Bosch 2021] BOSCH: *Help Connect vereint automatische Unfallerkennung, Notruffunktion und persönlichen Notfalldienst.* <https://www.bosch-presse.de/pressportal/de/de/help-connect-vereint-automatische-unfallerkennung-notruffunktion-und-persoenlichen-notfalldienst-225737.html>. Version: März 2021. – Aufgerufen am 21.11.2022

[Brunskill 2019] BRUNSKILL, Vicki-Lynn: *Sprint (software development)*. <https://www.techtarget.com/searchsoftwarequality/definition/Scrum-sprint>. Version: August 2019. – Aufgerufen am 26.09.2022

[Bussgeldkataloge 2022] BUSSGELDKATALOGE: *Schrittgeschwindigkeit*. <https://www.bussgeldkataloge.de/schrittgeschwindigkeit/>. Version: September 2022. – Aufgerufen am 18.10.2022

[Cossalter u. a. 2014] Kapitel 1. In: COSSALTER, Vittore ; LOT, Roberto ; MASSARO, Matteo: *Motorcycle Dynamics*. John Wiley and Sons, Ltd, 2014. – ISBN 9781118536391, 1-42

[Deiss 1999] DEISS, J. Yeazel; J. Mehaffey; S. Penrod; A.: *GPS Speed*. <http://www.gpsinformation.net/main/gpsspeed.htm>. Version: Oktober 1999

[Developers 2022] DEVELOPERS, Android: *Motion sensors*. https://developer.android.com/guide/topics/sensors/sensors_motion#sensors-motion-accel. Version: August 2022. – Aufgerufen am 01.08.2022

[Elbayoumy 2018] ELBAYOUMY, Mahmoud Hany M.: *MOBILITAPP PROJECT: USER TRANSPORTATION ACTIVITYRECOGNITION VIA MOBILE DEVICESSENSORS*, TALLINN UNIVERSITY OF TECHNOLOGY, Diplomarbeit, 2018. <file:///E:/Eagleget/ce3b057f59404cb298543bdc3a2d165e.pdf>

[FAA 2021] FAA: *Satellite Navigation - GPS - How It Works*. https://www.faa.gov/about/office_org/headquarters_offices/ato/service_units/techops/navservices/gnss/gps/howitworks. Version: Februar 2021. – Aufgerufen am 01.08.2022

- [Gibbons 2021] GIBBONS, Jordan: *New smartphone tech could save your life after a crash.* <https://www.motorcyclenews.com/news/new-tech/bosch-accident-detection-system/>. Version: April 2021. – Aufgerufen am 21.11.2022
- [H. Appel 2002] H. APPEL, D. V. G. Krabbel K. G. Krabbel: *Unfallforschung, Unfallmechanik und Unfallrekonstruktion.* 2002
- [Hädrich 2012] HÄDRICH, Christian: *Messung der Schräglage von Motorrädern bei Kurvendurchfahrt,* RWTH Aachen University, Diplomarbeit, 2012
- [Iov u. a. 2004] Iov, F. ; HANSEN, A. D. ; SORENSEN, P. ; BLAABJERG, F.: Wind Turbine Blockset in Matlab/ Simulink / Institute of Energy Technology, Aalborg University. Version: 2004. <https://www.osti.gov/etdeweb/servlets/purl/20613486.2004>. – Forschungsbericht
- [Joy 2021] JOY, Ashwin: *26 Real-world Applications of C Language.* <https://pythonistaplanet.com/applications-of-c-language/>. Version: September 2021. – Aufgerufen am 22.11.2022
- [Karris 2008] KARRIS, S. T.: *Introduction to Simulink® with Engineering Applications.* Orchard Publications, 2008
- [Kasnakoglu 2015] KASNAKOGLU, C. A. Cansalar; E. Mavis; C.: Simulation Time Analysis of MATLAB/Simulink and LabVIEW for Control Applications. (2015). <https://ieeexplore.ieee.org/stamp/stamp.jsp?arnumber=7125143>
- [d. Maire 2020] MAIRE, F. d.: *Analyse der Verkehrssicherheit von Motorradfahrern zur prädiktiven Bestimmung von Normalfahrsituationen über kritische Situationen bis hin zu Unfällen.* 2020
- [Mathworks 2021] MATHWORKS: *MATLAB Coder.* <https://de.mathworks.com/products/matlab-coder.html>. Version: März 2021. – Aufgerufen am 21.11.2022
- [Moon 2020] MOON, M.: *Bosch's motorcycle crash detection automatically alerts emergency services.* https://www.engadget.com/bosch-motorcycle-crash-detection-060119306.html?guccounter=1&guce_referrer=aHR0cHM6Ly93d3cuZ29vZ2x1LmNvbS8&guce_referrer_sig=AQAAAE05v4vQ2LxqWJwKws16fqWaBtz5N81h_NHY6tnlys7ci9h1HgbYbMQnJ50JEBRXTxbPtEPRf42-XWJZTudIR8h3FYY0Evu5HSVRwDT2J2V-SgOcyVx_RlikDEJCzr6h9UdB8714YwN2Em67tCncHmoNrBhKvFdnhnOsZ9P91DT7. Version: Juni 2020. – Aufgerufen am 21.11.2022
- [MostrandomComps 2019] MOSTRANDOMCOMPS: *Motorcycle Crash Compilation.* https://www.youtube.com/watch?v=dMsYT_7xNfg&ab_channel=MostrandomComps. Version: November 2019. – Aufgerufen am 06.09.2022

[Moto-Passion 2018a] MOTO-PASSION: *Animals Vs Bikers*. https://www.youtube.com/watch?v=KiRydLwtAyc&ab_channel=MotoPassion. Version: Juli 2018. – Aufgerufen am 06.09.2022

[Moto-Passion 2018b] MOTO-PASSION: *CRAZY Driver Vs Biker*. https://www.youtube.com/watch?v=HFig7J40mT8&ab_channel=MotoPassion. Version: Dezember 2018. – Aufgerufen am 06.09.2022

[Moto-Passion 2018c] MOTO-PASSION: *Motorcycle Crashes and Mishaps*. https://www.youtube.com/watch?v=jLm0b4Mq-pQ&ab_channel=MotoPassion. Version: Juli 2018. – Aufgerufen am 06.09.2022

[Moto-Passion 2018d] MOTO-PASSION: *Motorcycle Crashes on the Road*. https://www.youtube.com/watch?v=S_lizETnMpk&ab_channel=MotoPassion. Version: Juli 2018. – Aufgerufen am 06.09.2022

[N. Kehtarnavaz 2006] N. KEHTARNAVAZ, C. G.: DSP System Design using LabVIEW and Simulink: A Comparative Evaluation. (2006). <https://ieeexplore.ieee.org/stamp/stamp.jsp?arnumber=1660510>

[Nasa 2019] NASA: *How Does GPS Work?* <https://spaceplace.nasa.gov/gps/en/>. Version: Juni 2019. – Aufgerufen am 01.08.2022

[NTI-Audio 2019] NTI-AUDIO: *Fast Fourier Transformation FFT - Basics*. <https://www.nti-audio.com/en/support/know-how/fast-fourier-transform-fft>. Version: Dezember 2019

[Rasheed u. a. 2015] RASHEED, Muhammad B. ; JAVAID, Nadeem ; ALGHAMDI, Turki A. ; MUKHTAR, Sana ; QASIM, Umar ; KHAN, Zahoor A. ; RAJA, M. Haris B.: Evaluation of Human Activity Recognition and Fall Detection Using Android Phone. In: *2015 IEEE 29th International Conference on Advanced Information Networking and Applications*, 2015, 163-170

[Rogers 2020] ROGERS, K.: *gyroscope*. Encyclopedia Britannica. <https://www.britannica.com/technology/inertial-guidance-system>. Version: Februar 2020. – Aufgerufen am 01.08.2022

[Sathish 2021] SATHISH: *How to Measure Acceleration in Smartphones using Accelerometer?* <https://blog.contus.com/how-to-measure-acceleration-in-smartphones-using-accelerometer/>. Version: November 2021. – Aufgerufen am 01.08.2022

[Schanze 2017] SCHANZE, Robert: *Gyroskop-Sensor im Handy: Was macht er? Wie funktioniert's?* <https://www.giga.de/apps/android/specials/gyroskop-sensor-im-handy-was-macht-er-wie-funktionierts-einfach-erklaert/>. Version: März 2017. – Aufgerufen am 19.12.2022

- [Schnee u. a. 2021] SCHNEE, Jan ; STEGMAIER, Jürgen ; LI, Pu: A probabilistic approach to online classification of bicycle crashes. In: *Accident Analysis and Prevention* 160 (2021), 106311. <http://dx.doi.org/https://doi.org/10.1016/j.aap.2021.106311>. – DOI <https://doi.org/10.1016/j.aap.2021.106311>. – ISSN 0001–4575
- [Sharma 2020] SHARMA, S.: *What Is Accelerometer? How to Use Accelerometer in Mobile Devices?* <https://www.credencys.com/blog/accelerometer/>. Version: Juli 2020. – Aufgerufen am 01.08.2022
- [sparkfun 2022] SPARKFUN: *Gyroscope*. <https://learn.sparkfun.com/tutorials/gyroscope/how-a-gyro-works>. Version: März 2022. – Aufgerufen am 01.08.2022
- [Tran u. Phan 2016] TRAN, Duc N. ; PHAN, Duy D.: Human Activities Recognition in Android Smartphone Using Support Vector Machine. In: *2016 7th International Conference on Intelligent Systems, Modelling and Simulation (ISMS)*, 2016
- [Venkatraman u. a. 2021] VENKATRAMAN, V. ; RICHARD, C. M. ; MAGEE, K. ; JOHNSON, K.: *Countermeasures that work: A highway safety countermeasures guide for State Highway Safety Offices*. NHTSA, 2021 <https://www.nhtsa.gov/book/countermeasures/countermeasures-work/motorcycle-safety>. – Aufgerufen am 07.11.2022
- [Weisstein 2022] WEISSTEIN, E. W.: *Fast Fourier Transform*. <https://mathworld.wolfram.com/FastFourierTransform.html>. Version: Januar 2022. – Aufgerufen am 25.07.2022
- [WHO 2022] WHO: *Road traffic injuries*. <https://www.who.int/news-room/factsheets/detail/road-traffic-injuries>. Version: Juni 2022. – Aufgerufen am 01.08.2022

A Anhang

A.1 Matlab-Entscheidungsfunktion

```
1 function [motionClass, lastMotionClassTime, frequency, Inten] =  
2     getMotionClass(Intensity, freq, DuSpeed, lastMotionClass,  
3     lastMotionClassTime)  
4 %%%%%% function to detect the activity and differentiate  
5 %%%%%% between walking and driving. When a walking detected,  
6 %%%%%% the Crash detection should be paused.  
7 %%%%%%  
8 %%%%%% The function output should be a MotionClass-ID of 4 Classes  
9 %%%%%% ID = -1      => Error  
10 %%%%%% ID = 0      => No Movement  
11 %%%%%% ID = 1      => Walking  
12 %%%%%% ID = 2      => Driving  
13 %%%%%%  
14 % Check the biggest five frequencies. The idea is to determine the right  
15 % detected frequency  
16 for iFq = 1:5  
17     %% first check the intensity of the frequency to get only  
18     %% the frequency with an enough energy (intensity)  
19     if Intensity(iFq) > 100  
20         %% check the actual frequency. Three intervals are defined  
21         %% (walking, driving, between zones)  
22         if freq(iFq) >= 7  
23             %% high frequency detected (most likely driving)  
24  
25             %% doppel check with the speed  
26             if DuSpeed < 5  
27                 %% high frequency but very low speed => No Movement  
28                 motionClass = 0;  
29             else  
30                 %% there is movement => Driving  
31                 motionClass = 2;  
32             end  
33             break  
34  
35         elseif freq(iFq) >= 0.390625000 && freq(iFq) <= 2  
36             %% Low frequency, (most likely walking)  
37  
38             %% doppel check with the speed  
39             if DuSpeed <=7 && DuSpeed > 0
```

```

40         % walking speed => Walking
41         motionClass = 1;
42         break
43     elseif DuSpeed == 0
44         % no speed => no Movement
45         motionClass = 0;
46         break
47     else
48         % speed > 7 kmh => not walking => conflict
49         % => check next frequency
50         motionClass = -1;
51         continue;
52     end
53 elseif freq(iFq) > 2 && freq(iFq) <7
54     % Between zone. Maybe walking and maybe driving.
55
56     %% Double check with the speed.
57     %% If the speed is bigger than 7 km/h than he must
58     %% be driving. If the speed is smaller than 7 km/h
59     %% it should stay undeclared.the person might be
60     %% driving with no GPS-Signal (e.g. no speed)
61 if DuSpeed >= 7
62     % Driving speed => Driving
63     motionClass = 2;
64     break;
65 else
66     % Not driving speed => Conflict => check next frequency
67     motionClass = -1;
68     continue;
69 end
70 else
71     % not intended to get here; all usecases were
72     % defined previously
73     motionClass = lastMotionClass; % keep last detected class
74     break
75 end
76 else
77     % The intensity is smaller than 100 => the frequency could 't
78     % be used => determine motionClass only using the speed
79 if DuSpeed >= 7
80     % Driving speed => Driving
81     motionClass = 2;
82     break;
83 elseif DuSpeed < 7 && DuSpeed > 0.1
84     % Walking speed => Walking
85     motionClass = 1;
86     break;
87 else
88     % Speed = 0 => No movement
89     motionClass = 0;
90 end
91 end

```

```
92 end  
93 % save the frequency used to determine motionClass  
94 frequency = freq(iFq);  
95 % save the intensity used to determine motionClass  
96 Inten = Intensity(iFq);  
97 end
```


Eidesstattliche Erklärung

Ich erkläre an Eides statt, dass ich die vorliegende Master-Arbeit selbstständig und ohne fremde Hilfe verfasst, andere als die angegebenen Quellen und Hilfsmittel nicht benutzt und die den benutzten Quellen wörtlich oder inhaltlich entnommenen Stellen als solche kenntlich gemacht habe.

Ort und Datum: Stuttgart, den _____ Unterschrift: _____